8장. 머신러닝 및 딥러닝

python™

구글 코렙

❖ Google Colab 사용하기

Colaboratory는 **구글의 Jupyter Notebook 기반 클라우드 서비스**로, TPU나 GPU, CPU를 무료 제공하며 클라우드 IDE의 일부이다

- 계정 로그인 > 메뉴(선택) > **드라이브**

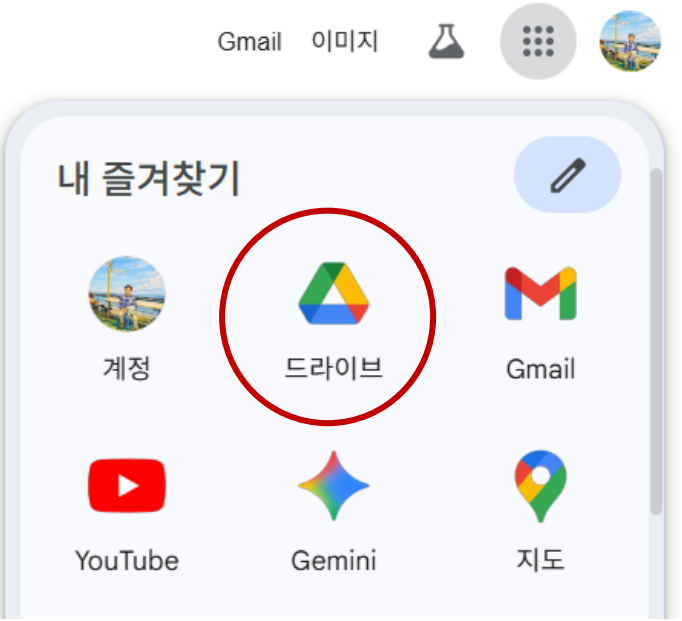

구글 코랩

❖ 리소스 사용 – 클라우드 컴퓨터 사용

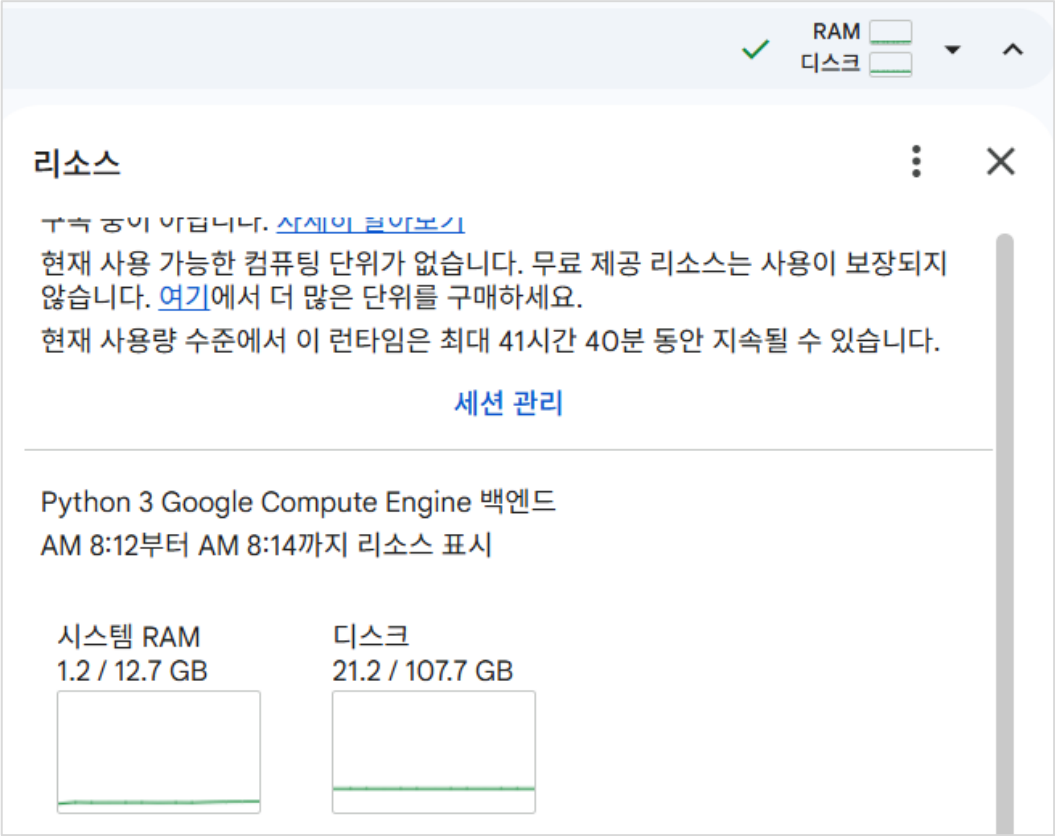

구글 코랩

❖ 구글 코랩(Colaboratory)

AI(Gemini) 지원 : 설정 > AI 지원 > 동의

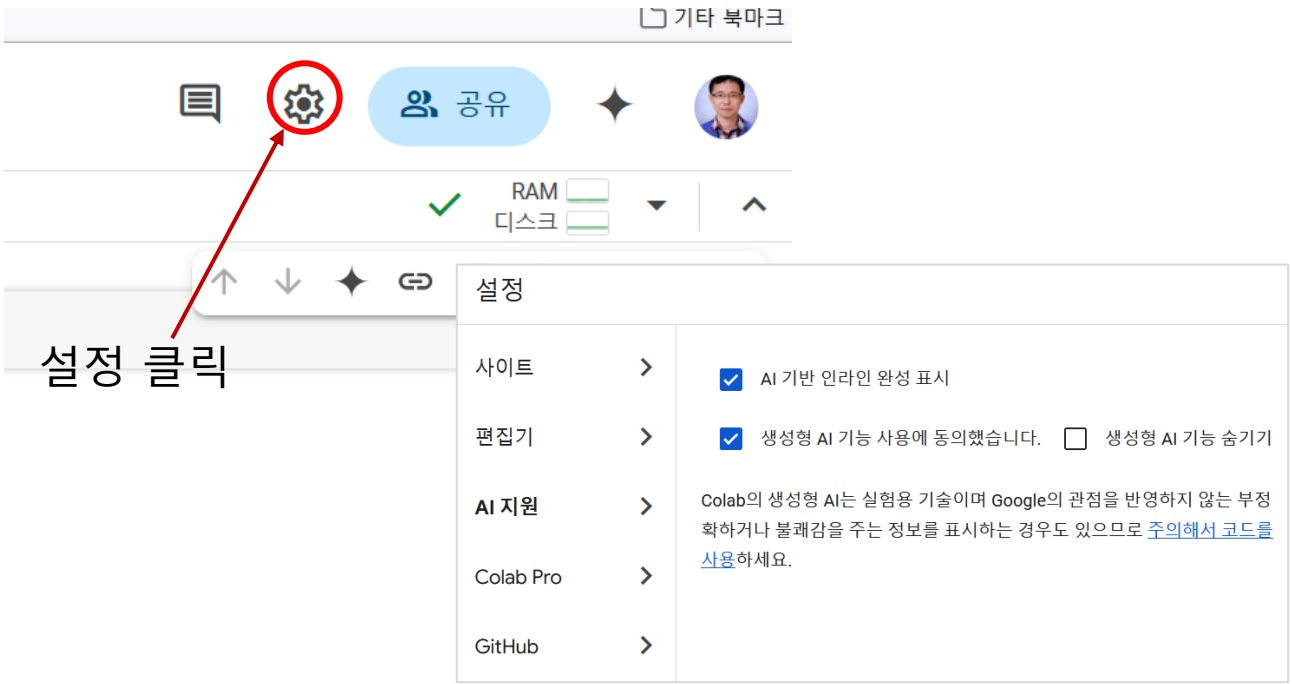

구글 코렙

❖ 새 노트 만들기

- 드라이브 > 홈
- + 신규 > 더보기 > Google Colaboratory

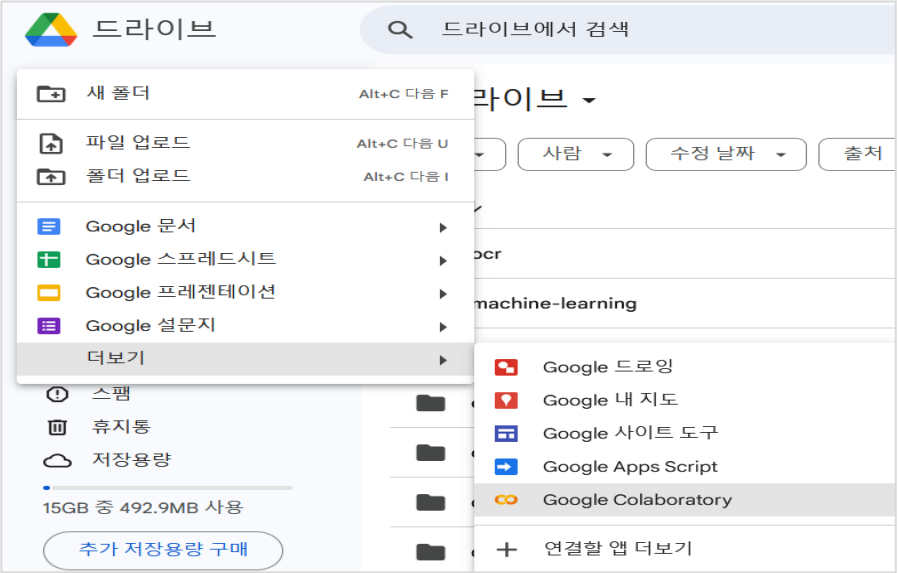

구글 코랩

❖ 새 노트 만들기

- 파일이름 > note01.ipynb

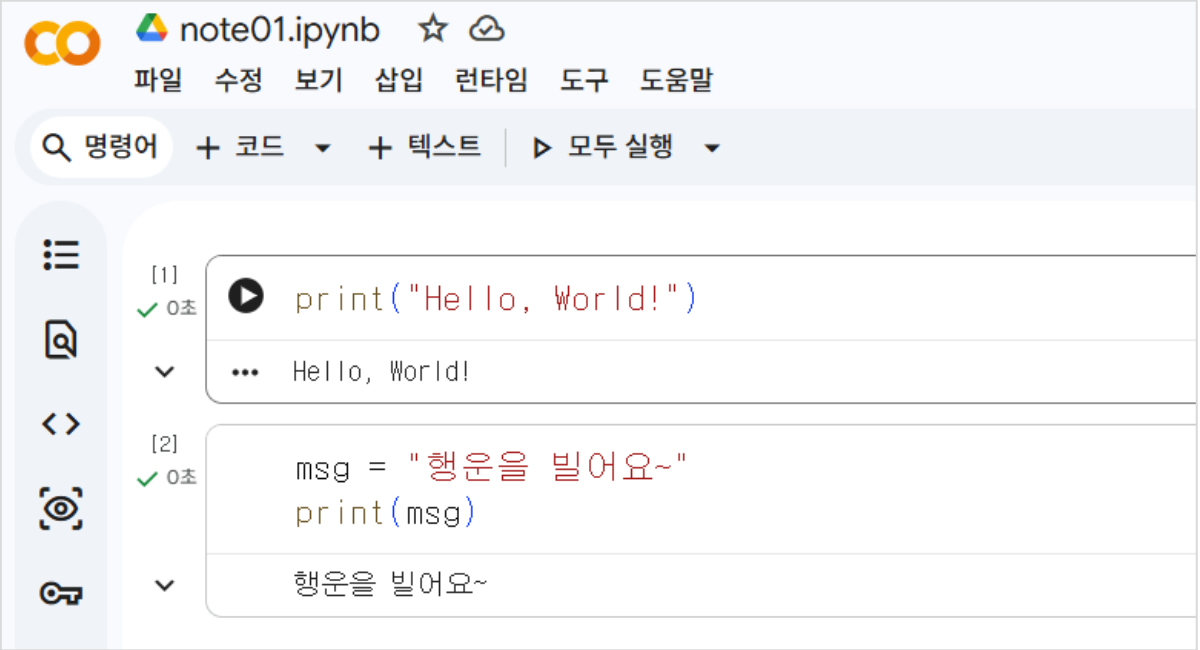

구글 코랩

❖ 새 노트 만들기

- 파일이름 > note01.ipynb

```python
import pandas as pd

df = pd.DataFrame({
    "name": ['마우스', '모니터'],
    "price": [20000, 80000]
})

df
```

	name	price
0	마우스	20000
1	모니터	80000

다음 단계: df 변수로 코드 생성 New interactive sheet

구글 코랩

❖ 새 폴더 만들기

- 드라이브 > 내 드라이브
- + 신규 > 새폴더> 머신러닝

구글 코랩

❖ 텍스트 사용하기

- 파일 이름 : 선형회귀.ipynb
- 텍스트(버튼) > 문서의 제목을 만들때 사용

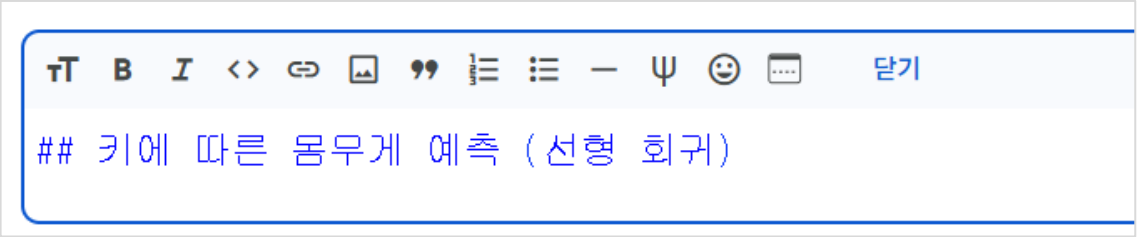

<편집화면>

shift + enter

키에 따른 몸무게 예측 (선형 회귀)

<출력화면>

상관 분석 vs 회귀 분석

- **상관 분석 vs 회귀 분석**

상관 분석	회귀 분석
x와 y의 관련 정도를 확인	x가 y에 주는 영향을 추정하여 결과를 예측할 수 있음
산포도, 상관 계수	회귀식
광고비와 매출은 양의 상관관계가 있다.	광고비를 1% 늘리면 매출이 5% 증가할 것이다.

10

자동차 사고 상관 분석

- **데이터 준비 및 탐색**

```python
import seaborn as sns

# 데이터 준비 - 자동차 사고
df = sns.load_dataset('car_crashes')
df.head()
```

	total	speeding	alcohol	not_distracted	no_previous	ins_premium	ins_losses	abbrev
0	18.8	7.332	5.640	18.048	15.040	784.55	145.08	AL
1	18.1	7.421	4.525	16.290	17.014	1053.48	133.93	AK
2	18.6	6.510	5.208	15.624	17.856	899.47	110.35	AZ
3	22.4	4.032	5.824	21.056	21.280	827.34	142.39	AR
4	12.0	4.200	3.360	10.920	10.680	878.41	165.63	CA

11

자동차 사고 상관 분석

- **데이터 준비 및 탐색**

데이터셋에 포함된 각 칼럼의 의미를 설명해 줘

+ Gemini 3 Flash

변수	의미
total	10만 명당 총 사고 건수
speeding	과속 관련 사고 비율
alcohol	음주 관련 사고 비율
not_distracted	비산만 상태 사고 비율
no_previous	이전 사고 기록 없음 비율
ins_premium	보험료
ins_losses	보험 손실 비용
abbrev	주 약자 (문자형 → 상관분석 제외됨)

12

자동차 사고 상관 분석

- **데이터 정보**

```python
# 데이터 탐색
df.info()

# 통계 요약
df.describe()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 51 entries, 0 to 50
Data columns (total 8 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   total           51 non-null     float64
 1   speeding        51 non-null     float64
 2   alcohol         51 non-null     float64
 3   not_distracted  51 non-null     float64
 4   no_previous     51 non-null     float64
 5   ins_premium     51 non-null     float64
 6   ins_losses      51 non-null     float64
 7   abbrev          51 non-null     object
dtypes: float64(7), object(1)
memory usage: 3.3+ KB
```


13

자동차 사고 상관 분석

- **통계 요약**

	total	speeding	alcohol	not_distracted	no_previous	ins_premium	ins_losses
count	51.000000	51.000000	51.000000	51.000000	51.000000	51.000000	51.000000
mean	15.790196	4.998196	4.886784	13.573176	14.004882	886.957647	134.493137
std	4.122002	2.017747	1.729133	4.508977	3.764672	178.296285	24.835922
min	5.900000	1.792000	1.593000	1.760000	5.900000	641.960000	82.750000
25%	12.750000	3.766500	3.894000	10.478000	11.348000	768.430000	114.645000
50%	15.600000	4.608000	4.554000	13.857000	13.775000	858.970000	136.050000
75%	18.500000	6.439000	5.604000	16.140000	16.755000	1007.945000	151.870000
max	23.900000	9.450000	10.038000	23.661000	21.280000	1301.520000	194.780000

14

자동차 사고 상관 분석

- **상관 계수 및 시각화**

상관 계수의 의미에 대해 설명해 줘

Gemini 3 Flash

상관 계수(Correlation Coefficient)는 두 변수 사이의 관계가 얼마나 밀접한지, 그리고 어떤 방향으로 움직이는지를 수치로 나타낸 것입니다. 보통 **피어슨 상관 계수**를 가장 많이 사용하며, 값의 범위는 **-1에서 1 사이**입니다.

각 수치가 의미하는 바는 다음과 같습니다:

1. **1에 가까울수록 (양의 상관관계)**:
    - 한 변수가 증가할 때 다른 변수도 함께 증가하는 관계입니다.
    - 예: 공부 시간이 늘어날수록 시험 점수가 올라가는 경향.
2. **-1에 가까울수록 (음의 상관관계)**:
    - 한 변수가 증가할 때 다른 변수는 감소하는 반비례 관계입니다.
    - 예: 운동량이 많아질수록 체지방률이 낮아지는 경향.
3. **0에 가까울수록 (상관관계 없음)**:

15

자동차 사고 상관 분석

- 상관 계수 및 시각화

```
# 상관 계수
corr = df.select_dtypes(include=['number']).corr()
corr
```

	total	speeding	alcohol	not_distracted	no_previous	ins_premium	ins_losses
total	1.000000	0.611548	0.852613	0.827560	0.956179	-0.199702	-0.036011
speeding	0.611548	1.000000	0.669719	0.588010	0.571976	-0.077675	-0.065928
alcohol	0.852613	0.669719	1.000000	0.732816	0.783520	-0.170612	-0.112547
not_distracted	0.827560	0.588010	0.732816	1.000000	0.747307	-0.174856	-0.075970
no_previous	0.956179	0.571976	0.783520	0.747307	1.000000	-0.156895	-0.006359
ins_premium	-0.199702	-0.077675	-0.170612	-0.174856	-0.156895	1.000000	0.623116
ins_losses	-0.036011	-0.065928	-0.112547	-0.075970	-0.006359	0.623116	1.000000

16

자동차 사고 상관 분석

- 상관 계수 및 시각화

```
# 시각화 - heatmap
import matplotlib.pyplot as plt

plt.figure(figsize=(8, 6))

sns.heatmap(corr, annot=True, cmap='coolwarm')
plt.title("Car Crash")
plt.xticks(rotation=45)
plt.show()
```


17

자동차 사고 상관 분석

- 상관 계수 및 시각화

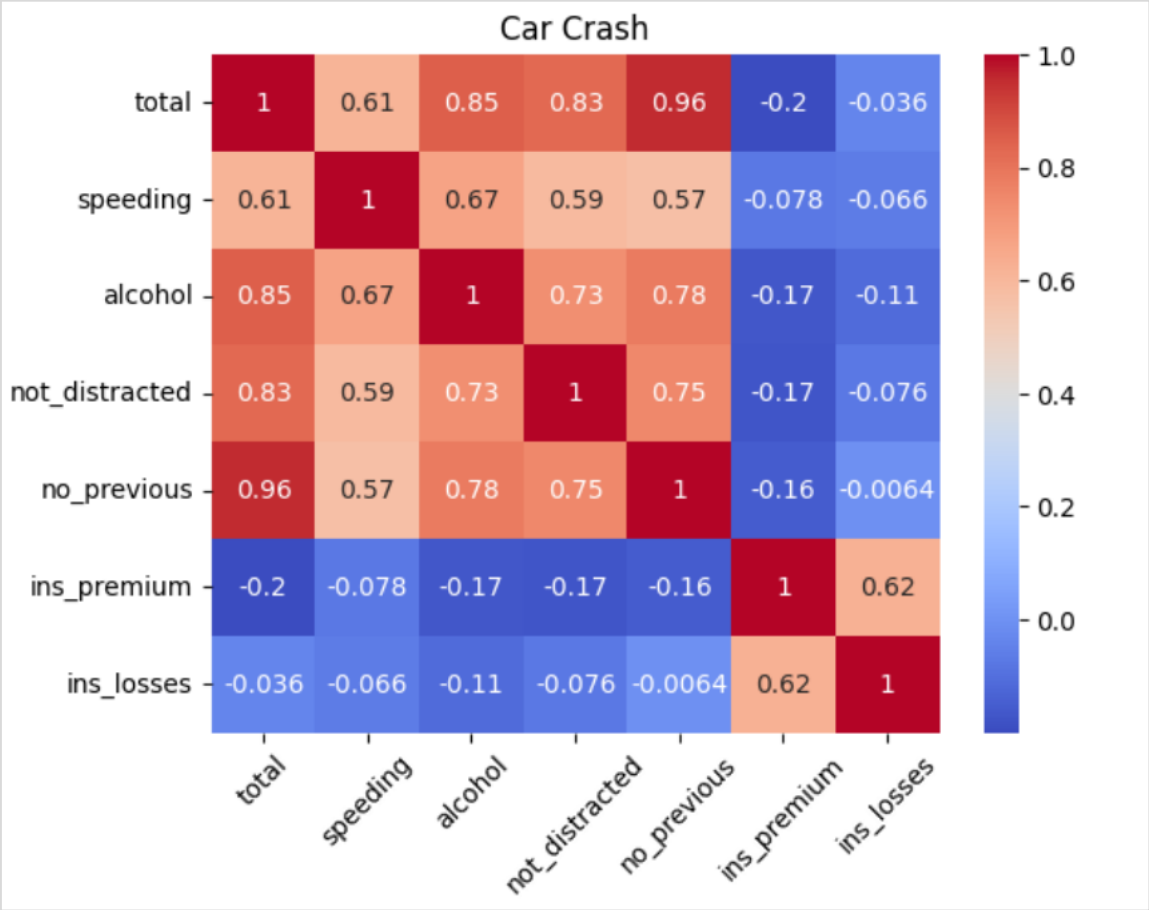

18

자동차 사고 상관 분석

- **주요 상관 관계 분석**

변수 1	변수 2	상관계수	관계 강도	해석
total	no_previous	0.956	매우 강한 양의 상관관계	총 사고 건수가 많을수록 이전 사고 기록이 없는 운전자 관련 사고도 많음
total	alcohol	0.853	강한 양의 상관관계	총 사고 건수가 많을수록 음주 관련 사고도 많음
total	not_distracted	0.828	강한 양의 상관관계	총 사고 건수가 많을수록 부주의하지 않은 운전 관련 사고도 많음
total	speeding	0.612	보통 수준의 양의 상관관계	총 사고 건수가 많을수록 과속 관련 사고도 많음
total	ins_premium	-0.200	약한 음의 상관관계	총 사고 건수와 보험료는 약한 음의 관계
total	ins_losses	-0.036	매우 약한 음의 상관관계	총 사고 건수와 보험 손실은 거의 관계 없음
alcohol	no_previous	0.784	강한 양의 상관관계	음주 관련 사고율이 높은 주에서 이전 사고 기록이 없는 운전자 비율도 높은 경향
ins_premium	ins_losses	0.623	보통에서 강한 양의 상관관계	높은 보험료가 높은 보험 손실과 연관됨

19

머신러닝(Machine Learning)

+ 머신러닝에 대해 설명해 줘

머신러닝이란? 명시적으로 규칙을 코딩하지 않아도, 데이터로부터 패턴을 학습해 예측·판단하는 인공지능 기술

머신러닝의 핵심 개념

1️⃣ **데이터**

- 학습의 재료
- 많고, 정확할수록 성능이 좋아짐

2️⃣ **모델(Model)**

- 데이터를 학습한 결과물
- 예: "이메일이 스팸일 확률은 92%"

3️⃣ **학습(Training)**

- 데이터를 보고 모델이 규칙을 조정하는 과정

4️⃣ **예측(Prediction)**

- 새로운 데이터에 대해 결과를 맞혀보는 것

머신러닝(Machine Learning)

❖ 지도 학습 vs 비지도 학습

	지도 학습	비지도학습
분석 모형 (알고리즘)	• 회귀 • 분류	• 군집 • 차원 축소
특징	• 정답(레이블)을 알고 있는 상태에서 학습 • 회귀 – 가격, 매출, 주가 예측 • 분류 – 고객분류, 질병 진단, 스팸 메일 필터링	• 정답(레이블)이 없는 상태에서 서로 비슷한 데이터를 찾아서 그룹화(클러스터링) • 구매 패턴 분석, 유투브 추천 등

머신러닝(Machine Learning)

❖ **지도 학습**

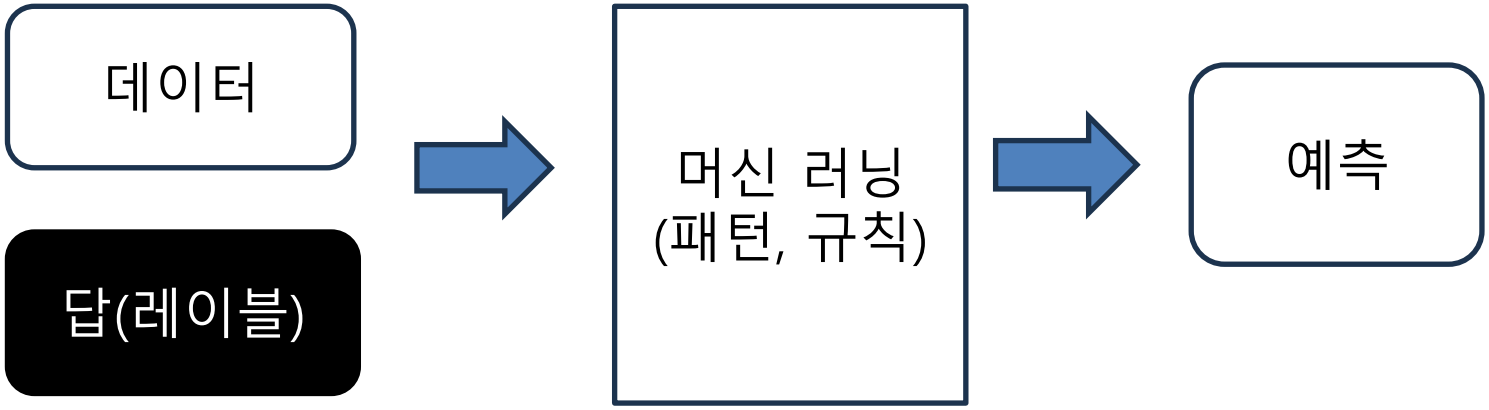

머신러닝(Machine Learning)

❖ **비지도 학습**

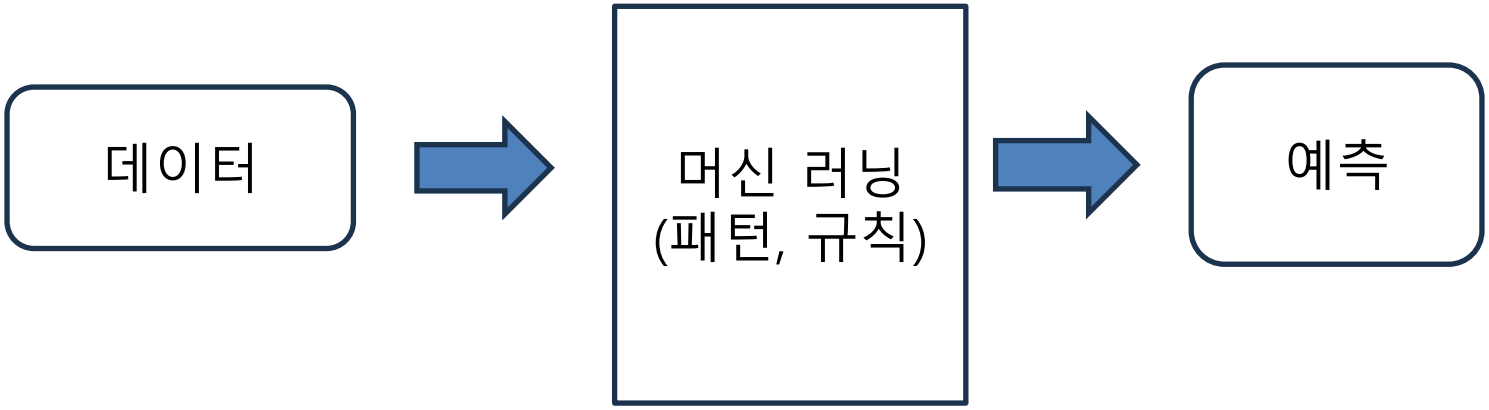

머신러닝(Machine Learning)

❖ 강화 학습

- 강화란 '어떤 것의 수준이나 정도를 높인다'는 의미로 인공지능의 수준을 높이는 것을 말한다.
- 에이전트가 환경과 상호작용하면서 보상 신호에 따라 최적의 정책을 찾아내는 방법

- 벽돌깨기 게임 – 딥마인드(구글) 회사
- 알파고(딥마인드) – 바둑을 학습한 인공지능
- 자율주행 자동차, 인공지능 로봇으로 확장되고 있음

회귀(Regression)

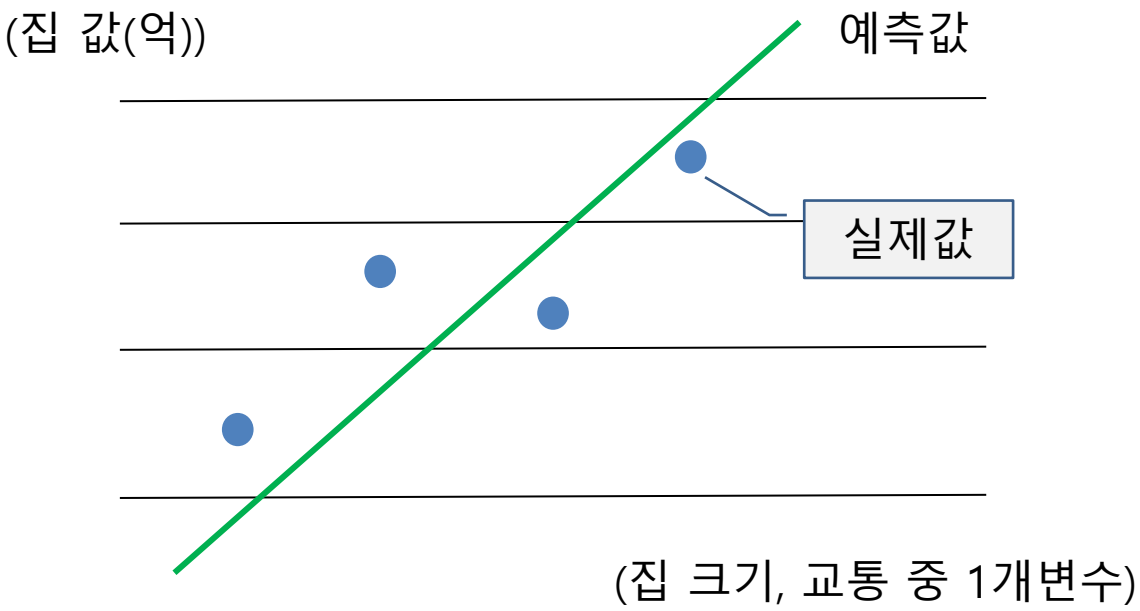

분류(Classification)

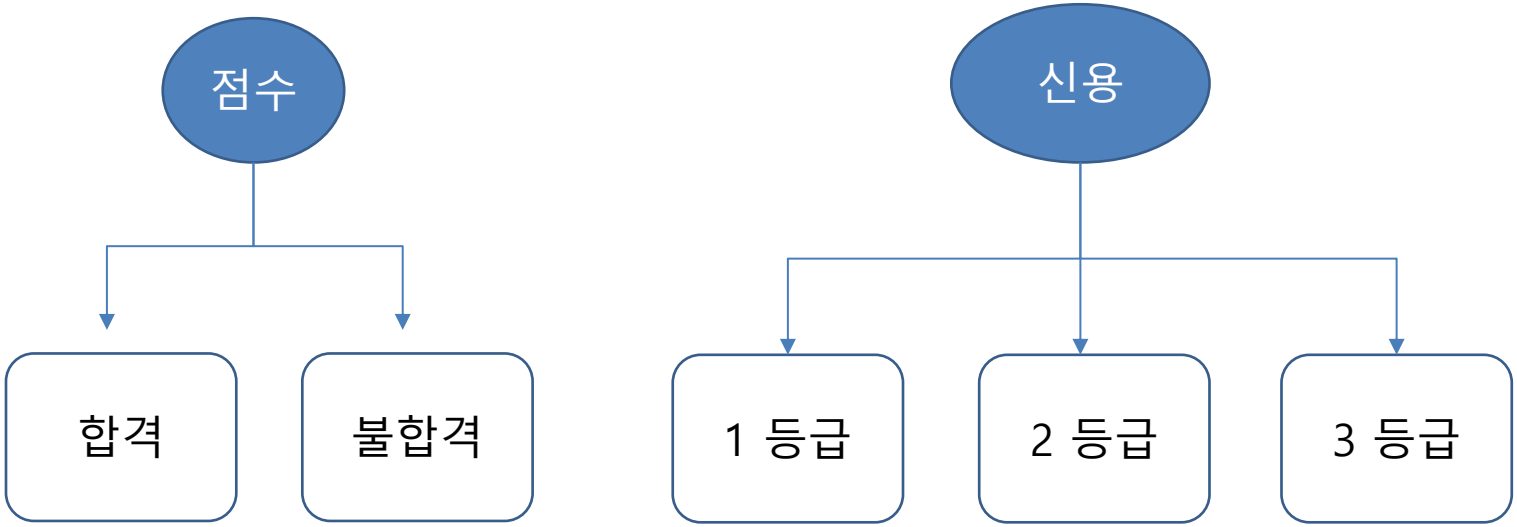

머신러닝 프로세스

- **머신러닝 모델 예측 프로세싱**

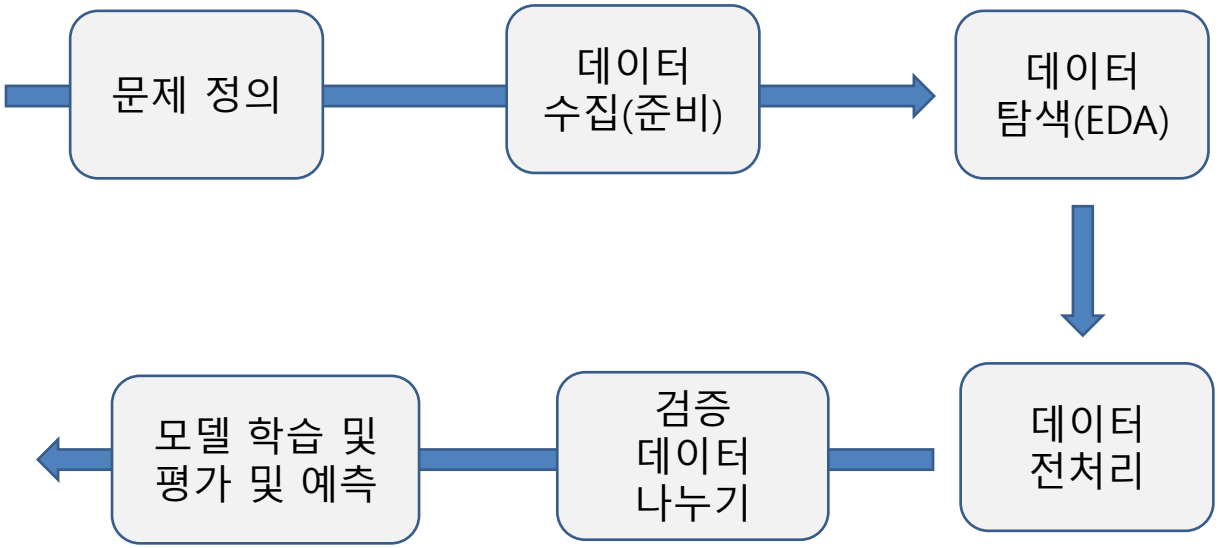

데이터 수집(준비)

- **데이터는 학습용과 검증으로 준비한다.**
  - ✓ 훈련 : 검증 비율

    80 : 20 or 70 : 30

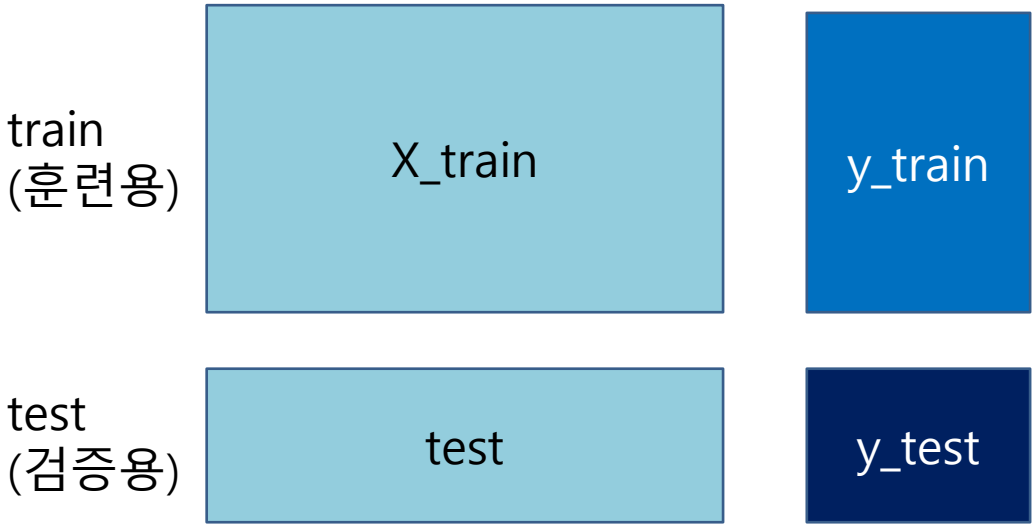

데이터 전처리

- **데이터 처리를 위한 모듈**

	알고리즘	필수 여부
레이블 인코딩	sklearn.preprocessing(모듈) LabelEncoder	필수 (원-핫 인코딩중 선택)
스케일링	sklearn. preprocessing(모듈) StandardScaler	선택
데이터 분할	sklearn. model_selection(모듈) train_test_split	필수

데이터 전처리

- **인코딩(Encoding) – 문자형을 숫자형으로 변환**
  - 레이블 인코딩(Label Encoding) : 각 칼럼을 숫자로 매핑하는 인코딩 방법이다.

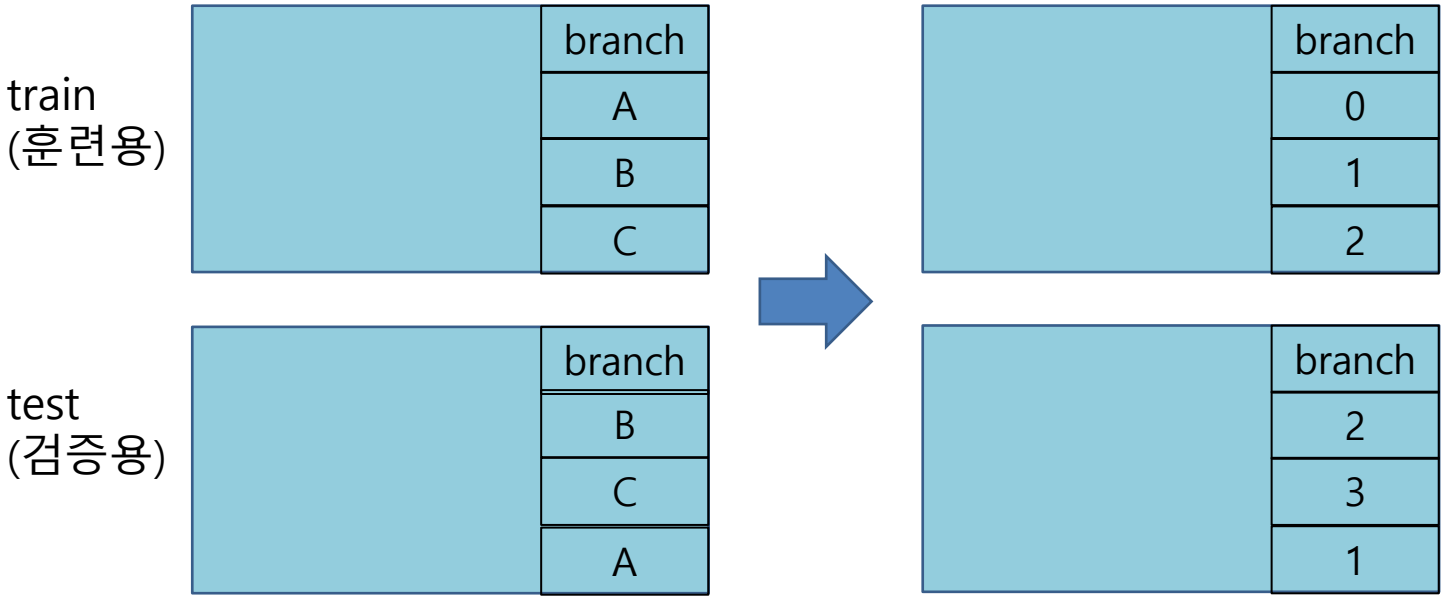

데이터 전처리

- **인코딩(Encoding) – 문자형을 숫자형으로 변환**
  - 원-핫 인코딩(One-Hot Encoding) : 각 칼럼에 대해 새로운 칼럼을 만들고 새로운 칼럼에 0 또는 1이 저장된다.

train
(훈련용)

branch
A
B
C

test
(검증용)

branch
B
C
A

branch_A	branch_B	branch_C
1	0	0
0	1	0
0	0	1

branch_A	branch_B	branch_C
0	1	0
0	0	1
1	0	0

모델 학습 및 평가

- **모델 학습 및 평가**

지도 학습	알고리즘	평가 지표
분류	sklearn.ensemble(모듈) RandomForestClassifier	sklearn.metrics(모듈) roc_auc_score, f1_score
회귀	sklearn.linear_model(모듈) LinearRegression sklearn.ensemble(모듈) RandomForestRegressor	sklearn.metrics(모듈) mean_squared_error mean_absolute_error

모델 학습 및 평가

- **모델 학습, 평가 및 예측**

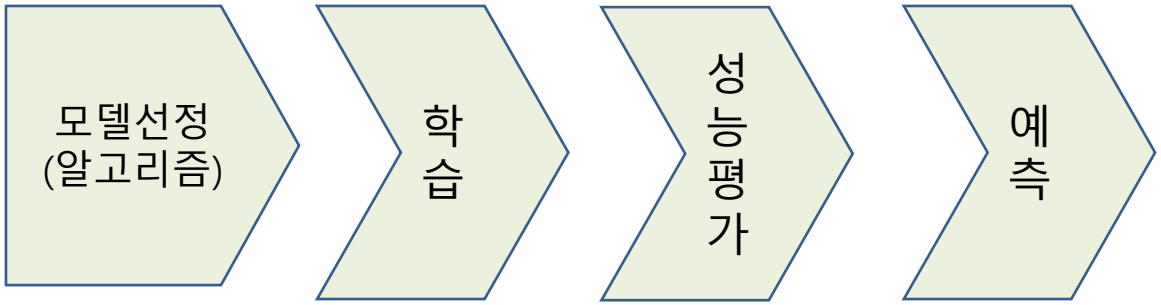

회귀(Regression)

- **선형 회귀**

머신러닝 회귀 모델중 선형회귀에 대해서 설명해 줘

선형회귀(Linear Regression)는 종속 변수(y)와 하나 이상의 독립 변수(X) 사이의 선형 상관관계를 모델링하는 머신러닝의 가장 기본적인 회귀 알고리즘입니다.

현재 노트북에 작성된 코드를 바탕으로 주요 특징을 설명해 드릴게요:

1. **핵심 원리**: 데이터들을 가장 잘 설명하는 하나의 직선($y = ax + b$$y = ax + b$)을 찾는 과정입니다. 여기서 $a$$a$는 기울기(Weight), $b$$b$는 절편(Bias)을 의미합니다.
2. **학습(Fit)**: `model.fit(X_train, y_train)` 코드를 통해 오차(실제값과 예측값의 차이)를 최소화하는 최적의 기울기와 절편을 계산합니다.

선형 회귀 분석

- **단순 선형 회귀**
  - $y=Wx+b$
  - W 를 가중치(Weight), b를 편향(bias)라고 부른다
  - 그래프의 형태는 **직선**
  - **가중치는 기울기, 편향은 절편이라고도 한다.**

- **다중 선형 회귀**
  - $y=W_1x_1 + W_2x_2 + \ldots + W_nx_n + b$
  - 만약 2개의 독립 변수면 그래프는 **곡선**으로 나타남

선형 회귀 분석

- **공부한 시간의 차이에 따른 시험 성적 예측하기**
  - 성적을 변하게 하는 요소를 x라 하고 이 x값에 따라 변하는 '성적'을 y라 하자.
  - 독립 변수(x) : 공부한 시간, 사교육비 지출, 학생의 지능지수 등
  - 종속 변수(y) : 성적
  - 어떤 변수가 다른 변수에 영향을 준다면 두 변수 사이에 선형관계가 있다.

선형 회귀 분석

- **공부한 시간의 차이에 따른 시험 성적 예측하기**

공부 시간	2시간	4시간	6시간	8시간
성적	81점	93점	91점	97점

x = {2, 4, 6, 8}

y = {81, 93, 91, 97}

직선의 방정식을 구한다.

$y = ax + b$(일차함수)

기울기 a와 절편 b를 알아야 함

최소 제곱법

- **최소 제곱법이란?**

선형 회귀의 최소제곱법에 대해 설명해 줘

선형 회귀에서 가장 핵심적인 개념인 **최소제곱법(Ordinary Least Squares, OLS)**에 대해 설명해 드릴게요.

최소제곱법은 실제값($y$$y$)과 모델의 예측값 ($"\hat{y}"$$"\hat{y}"$) 사이의 차이인 **오차(Residual)**를 제곱하여 모두 더한 값(SSE: Sum of Squared Errors)이 **최소가 되도록** 하는 회귀계수(기울기 $a$$a$와 절편 $b$$b$)를 찾는 방법입니다.

왜 그냥 더하지 않고 '제곱'을 할까요?

1. 오차가 양수(+)일 수도, 음수(-)일 수도 있어서 그냥 더하면 서로 상쇄되어 0이 될 수 있기 때문입니다.
2. 오차가 큰 데이터에 더 큰 페널티를 주어 모델이 전체적으로 데이터를 잘 따르게 만들기 위함입니다.

최소 제곱법

- **최소 제곱법이란?**

선형 회귀 모델의 목표는 다음 수식의 비용 함수(Cost Function)를 최소화하는 것입니다.

$$Loss = \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 = \sum_{i=1}^{n}(y_i - (ax_i + b))^2$$

- y_i: 실제값
- $\hat{y}_i$: 모델이 예측한 값
- $ax_i + b$: 선형 회귀식

이 식을 미분하여 기울기가 0이 되는 지점을 찾으면 최적의 a와 b를 구할 수 있습니다.

최소 제곱법

- **기초 통계 용어**
  - **편차(deviation)**

    관측값에서 평균을 뺀 값

  - **분산 (variance)**

    편차(관측값-평균)를 제곱하고 그것을 모두 더한 후
    전체 개수로 나눈것. 즉 편차의 제곱의 평균을 말한다.

  - **표준편차(standard deviation)**

    분산의 제곱근, 즉 분산 값에 루트를 씌운것을 말하며
    stdev라고 함.

최소 제곱법

- **키의 차이에 따른 몸무게 예측하기**
  - **기울기 a 구하기**

X의 편차(각 값과 평균과의 차이)를 제곱해서 합한 값을 분모로 놓고,
x와 y의 편차를 곱해서 합한 값을 분자로 놓으면 기울기가 나옴

$$a = \frac{(x - x\text{평균})(y - y\text{평균})\text{의 합}}{(x - x\text{평균})^2\text{의 합}}$$

공부 시간(x) 평균 : (2 + 4 + 6 + 8) ÷ 4 = 5
성적(y) 평균: (81 + 93 + 91 + 97) ÷ 4 = 90.5
기울기 a = 2.3

최소 제곱법

- **공부한 시간의 차이에 따른 시험 성적 예측하기**
  - **y절편 b값 구하기**

b = y의 평균 – (기울기 a x (x의 평균))

b = 90.5 – (2.3 x 5) = 79

최적의 직선(방정식)

$y = 2.3x + 79$

공부 시간	2	4	6	8
성적	81	93	91	97
예측 값	83.6	88.2	92.8	97.4

최소 제곱법

- 공부한 시간의 차이에 따른 시험 성적 예측하기

공부 시간	2	4	6	8
성적	81	93	91	97
예측 값	83.6	88.2	92.8	97.4

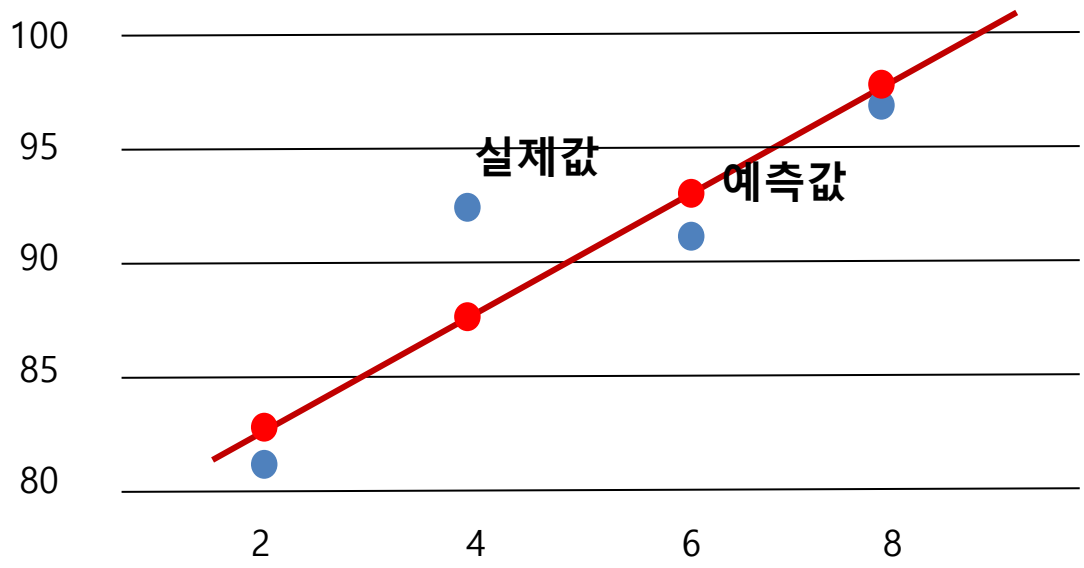

최소 제곱법

- **선형 회귀의 목적**

선형 회귀는 임의의 직선을 그어 이에 대한 평균 제곱 오차를 구하고, 이 값을 가장 작게 만들어주는 기울기(a)와 절편(b)을 찾아가는 작업이다.

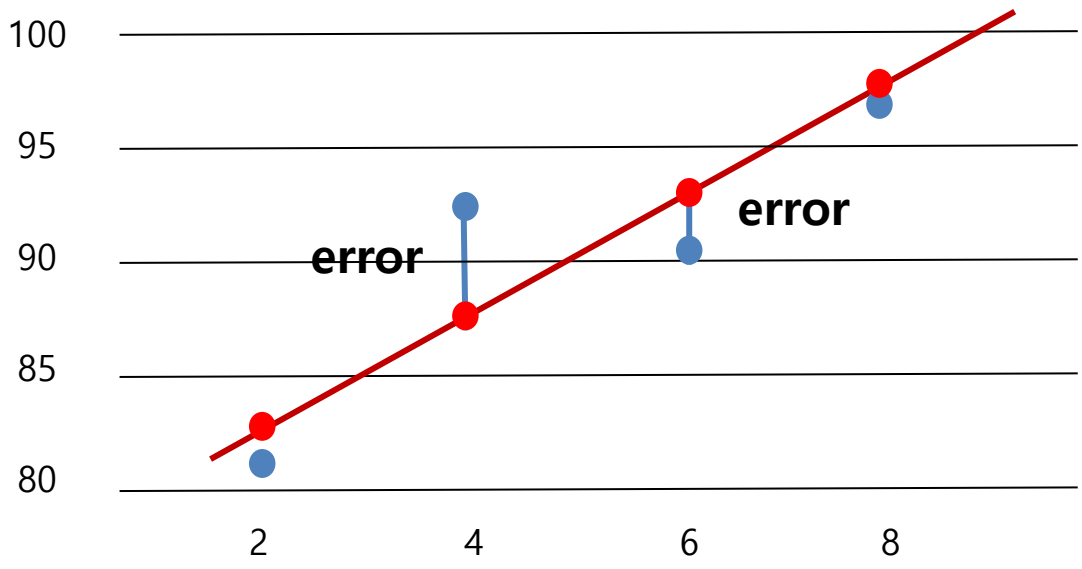

평균 제곱 오차

- **평균 제곱 오차**

선형 회귀의 평균제곱오차에 대해 설명해 줘

평균 제곱 오차(Mean Squared Error, MSE)는 회귀 모델의 성능을 평가하는 가장 대표적인 지표입니다.

앞서 설명해 드린 '최소제곱법'에서 구한 **오차 제곱의 합(SSE)을 전체 데이터 개수(n)로 나눈 값**입니다. 즉, 오차 제곱의 **평균**을 의미합니다.

1. **수식**: $MSE = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$$MSE = \frac{1}{n} \sum_{i=1}^{n} (y_i - \hat{y}_i)^2$
2. **의미**: 이 값이 작을수록 모델의 예측값과 실제값이 가깝다는 뜻이므로 성능이 좋다고 판단합니다.
3. **특징**: 오차를 제곱하기 때문에 1 미만의 작은 오차는 더 작아지고, 1 이상의 큰 오차는 훨씬 커집니다. 따라서 **이상치(Outlier)에 민감하게 반응**하는 특징이 있습니다.

평균 제곱 오차

- **성능 평가 - 평균 제곱 오차 / 평균 절대값 오차**

  - MSE(Mean Squared Error)
    - 평균 제곱오차
    - 오차의 제곱을 평균으로 나눈 것

$$MSE = \frac{\sum_{i=1}^{n}(y-\hat{y})^2}{n}$$

  - MAE(Mean Absolute Error)
    - 평균 절대값 오차
    - 오차의 차이를 절대값으로 변환한 뒤 합산

$$MAE = \frac{\sum |y-\hat{y}|}{n}$$

평균 제곱 오차

- **오차 = 실제값 – 예측값**

공부 시간	2	4	6	8
성적	81	93	91	97
예측 값	82	88	94	100
오차	**1**	**-5**	**3**	**3**

분모 : 1 + 25 + 9 + 9 = 44

MSE = 44 / 4 = 11

MAE = 1+5+3+3 = 12

구글 코랩

❖ 드라이브 마운트

- 폴더 > 드라이브 마운트 > 드라이브 연결

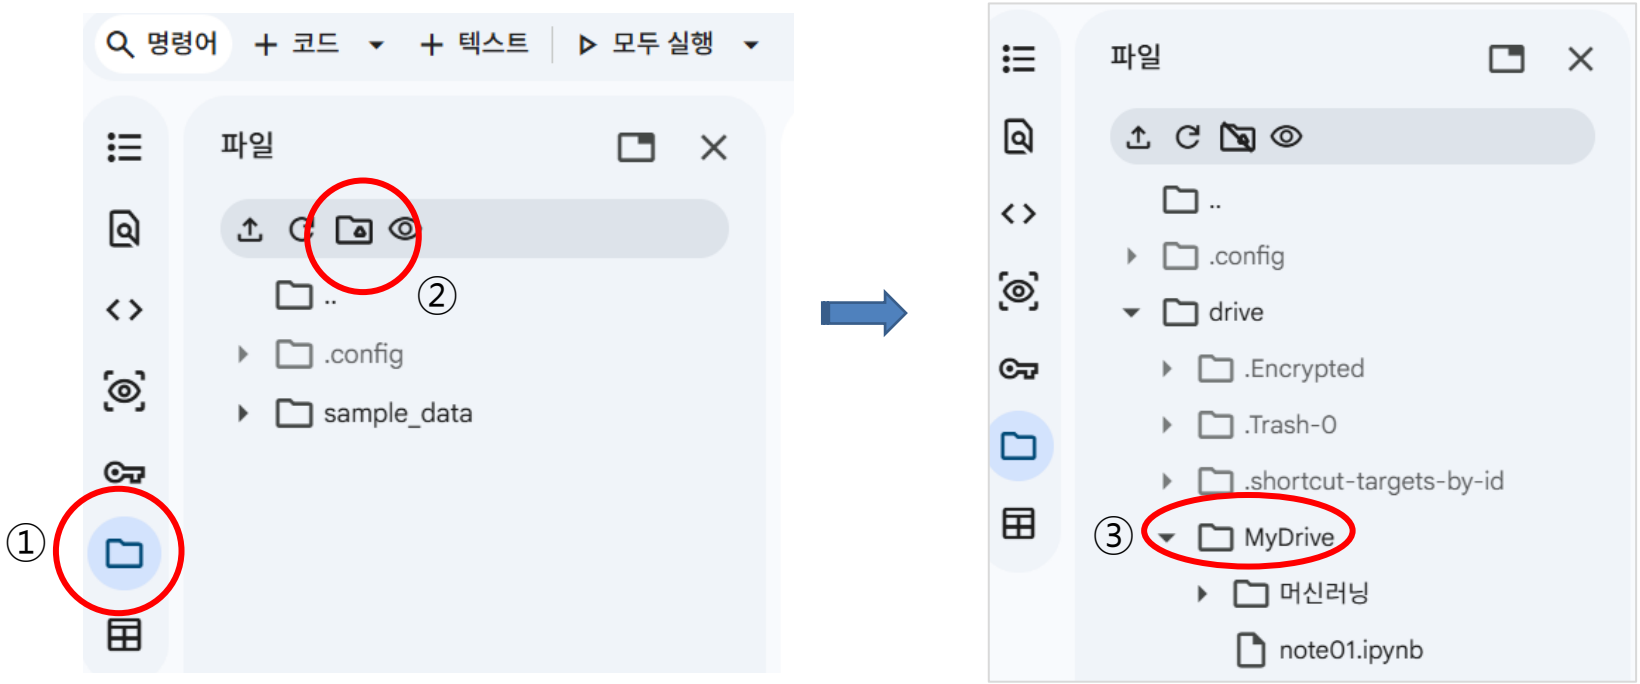

구글 코렙

❖ 훈련 데이터 업로드

- (...) 메뉴 > 업로드 > data_hw.csv

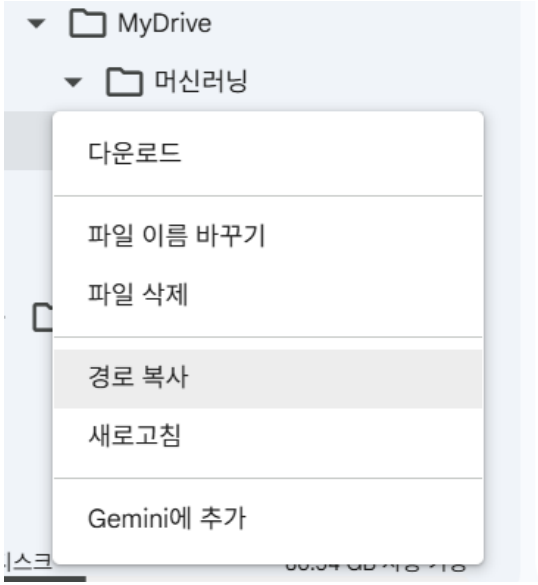

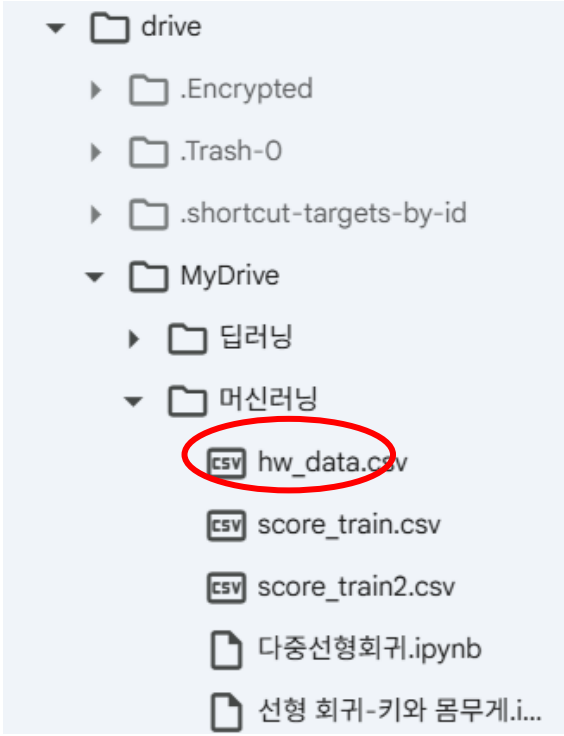

키에 따른 몸무게 예측

- **데이터 준비**

```
import pandas as pd

# 가상의 키와 몸무게 데이터 생성
data_hw = {
    '키': [150, 160, 170, 175, 165, 155, 172, 168, 174, 158,
           162, 173, 185, 159, 167, 163, 171, 169, 180, 161],
    '몸무게': [42, 50, 70, 65, 60, 48, 68, 60, 65, 40,
               54, 67, 89, 51, 65, 60, 69, 71, 85, 53]
}
df_hw = pd.DataFrame(data_hw)

# csv 파일로 저장하기
df_hw.to_csv("/content/drive/MyDrive/Machine-Learning/hw_data.csv", index=False)

df_hw.head()
```

키에 따른 몸무게 예측

- **데이터 탐색**

```
# csv 파일 읽기
df_hw = pd.read_csv("/content/drive/MyDrive/머신러닝/hw_data.csv")
print(df_hw)

# 데이터 탐색
df_hw.info()

df_hw.describe()
```

키에 따른 몸무게 예측

- **데이터 분할**

```
# 데이터 분할(훈련용/테스트용)
# 변수 선택
X = df_hw[['키']]  #독립변수 (여러 개일수 있어서 이차원리스트임)
y = df_hw['몸무게']  #종속변수

# print(X.head())
# print(y.head())

# 데이터 분할(훈련용<70%>:테스트용<30%>)
from sklearn.model_selection import train_test_split

X_train, X_test, y_train, y_test = train_test_split(X, y,
        test_size=0.3, random_state=11)
print(X_train.shape, X_test.shape, y_train.shape, y_test.shape)
```

```
(14, 1) (6, 1) (14,) (6,)
```

키에 따른 몸무게 예측

- **모델 학습 및 예측**

```
# 선형회귀 모델 생성
from sklearn.linear_model import LinearRegression

# 모델 생성
model = LinearRegression()

# 모델 학습
model.fit(X_train, y_train) #훈련용 데이터와 정답

# 모델 예측
pred = model.predict(X_train) #훈련용 데이터로 예측
print("예측 결과(일부):₩n", pred[:5])
```

```
예측 결과(일부):
 [56.20128991 48.88526282 81.07578201 59.12770074 70.83334408]
```

키에 따른 몸무게 예측

- **모델 시각화 – 한글 글꼴 설정**

```
import matplotlib.pyplot as plt
import matplotlib.font_manager as fm

# 나눔글꼴 설치
!apt-get -qq -y install fonts-nanum

# 폰트 경로 설정 및 적용
fontpath = '/usr/share/fonts/truetype/nanum/NanumBarunGothic.ttf'
font_name = fm.FontProperties(fname=fontpath).get_name()
plt.rc('font', family=font_name)

# 마이너스 기호 깨짐 방지
plt.rcParams['axes.unicode_minus'] = False

# 폰트 캐시 재구축 (최신 버전 방식)
fm.fontManager.addfont(fontpath)
```

키에 따른 몸무게 예측

- 모델 시각화(훈련용)

```
plt.scatter(X_train, y_train, label='Original Data') #산점도 그래프
plt.plot(X_train, pred, label='prediction', color='red') #선 그래프
plt.title("키에 따른 몸무게 선형회귀")
plt.xlabel('키(cm)')
plt.ylabel('몸무게(kg)')
plt.legend()
plt.show()
```

키에 따른 몸무게 예측

- 모델 시각화(훈련용)

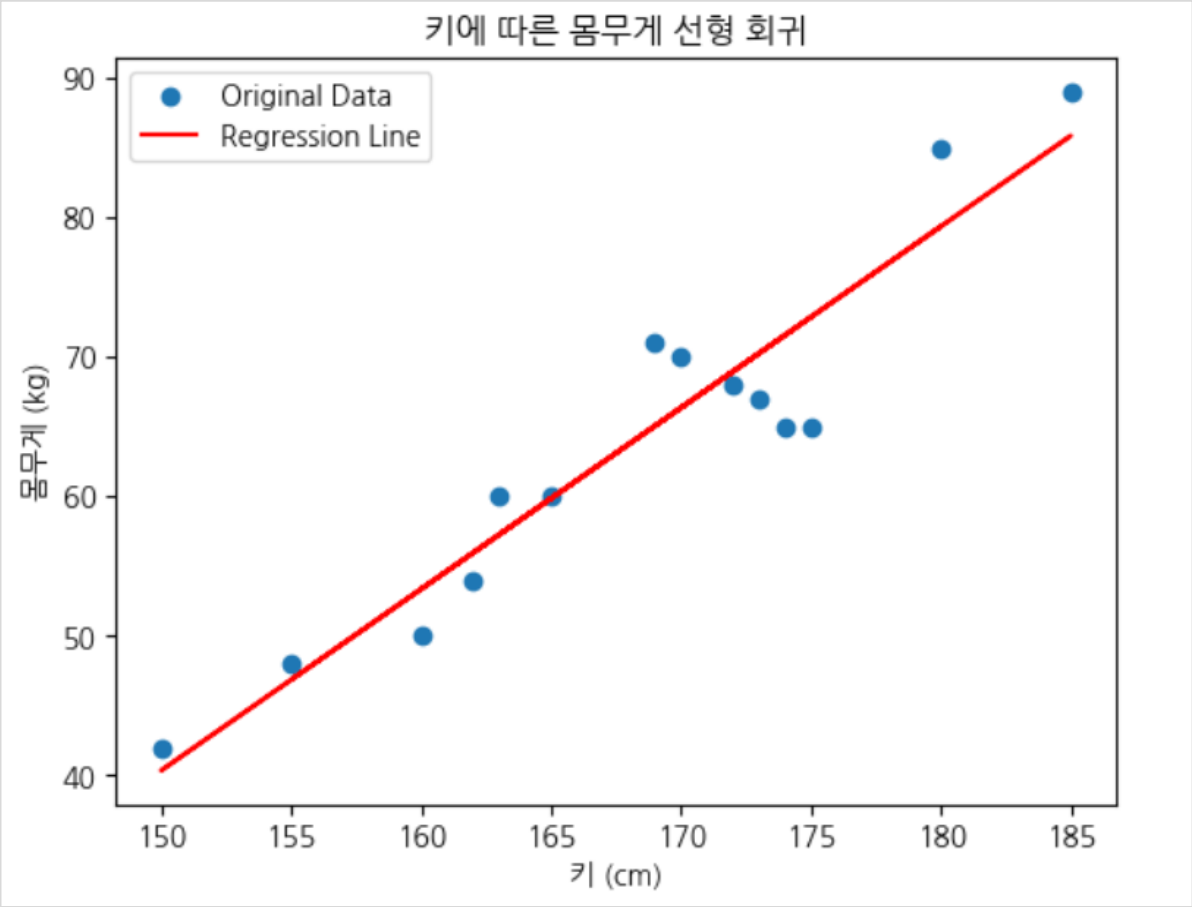

키에 따른 몸무게 예측

- 모델 시각화(테스트용)

```
plt.scatter(X_test, y_test, label='test') #산점도 그래프
plt.plot(X_test, model.predict(X_test), label='prediction', color='red')
plt.title("키에 따른 몸무게 선형회귀")
plt.xlabel('키(cm)')
plt.ylabel('몸무게(kg)')
plt.legend()
plt.show()
```

키에 따른 몸무게 예측

- 모델 시각화(테스트용)

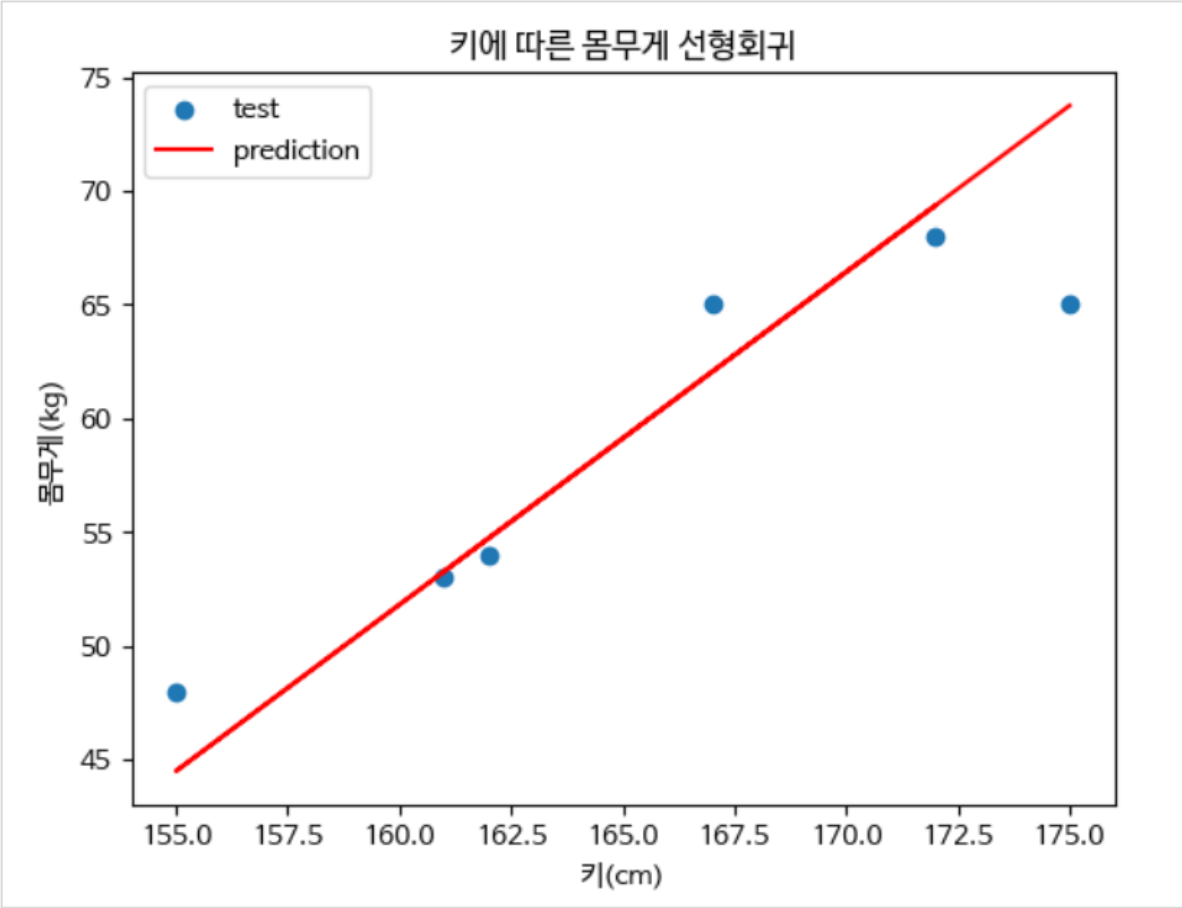

키에 따른 몸무게 예측

- **성능 평가**

```
# 성능 평가 - mse, rmse (결과값이 작을 수록 좋다.)
from sklearn.metrics import mean_squared_error
import numpy as np

y_pred = model.predict(X_test)
mse = mean_squared_error(y_test, y_pred) #(실제값, 예측값)
print(f"평균 제곱 오차(MSE): {mse:.4f}")

rmse = np.sqrt(mse)
print(f"평균 제곱근 오차(RMSE): {rmse:.4f}")
```

```
평균 제곱 오차(MSE): 23.6951
평균 제곱근 오차(RMSE): 4.8678
```

키에 따른 몸무게 예측

- **특정 데이터 예측**

```
# 몸무게 예측
height = 170
weight = model.predict([[height]])
print(f"{height}cm 인 사람의 몸무게는 {weight[0]:.2f}kg 입니다.")
```

```
170cm 인 사람의 몸무게는 66.44kg 입니다.
```

머신러닝과 딥러닝 비교

⚙️ 머신러닝 vs 딥러닝 한눈에 비교

구분	머신러닝	딥러닝
데이터	적어도 가능	많이 필요
특징 추출	사람이 설계	자동
계산량	적음	매우 큼
성능	보통	매우 높음

🎯 한 줄 요약

- **머신러닝**: 데이터로 규칙을 배우는 AI
- **딥러닝**: 신경망을 깊게 쌓아 더 똑똑하게 만든 머신러닝

딥러닝(Deep Learning)

- **딥러닝이란?**

딥러닝(Deep Learning)은 인공 신경망을 기반으로 하는 머신러닝의 한 분야입니다.
사람의 뇌가 작동하는 방식과 유사하게, 여러 계층(layer)의 신경망을 통해 데이터를 학습하고 복잡한 패턴을 인식하여 예측이나 분류 등의 작업을 수행합니다.

입력층 –> 은닉층 –> 은닉층 –> 출력층

딥러닝(Deep Learning)

- **인공 신경망**
  - **입력층(input layer)** – 데이터를 입력받는 층
  - **은닉층(hidden layer)** – 입력층에서 들어온 데이터가 여러 신호로 바뀌어 출력층까지 전달됨
  - **출력층(output layer)** – 출력층에 어떤 값이 전달되었는냐에 따라서 예측 값이 결정됨

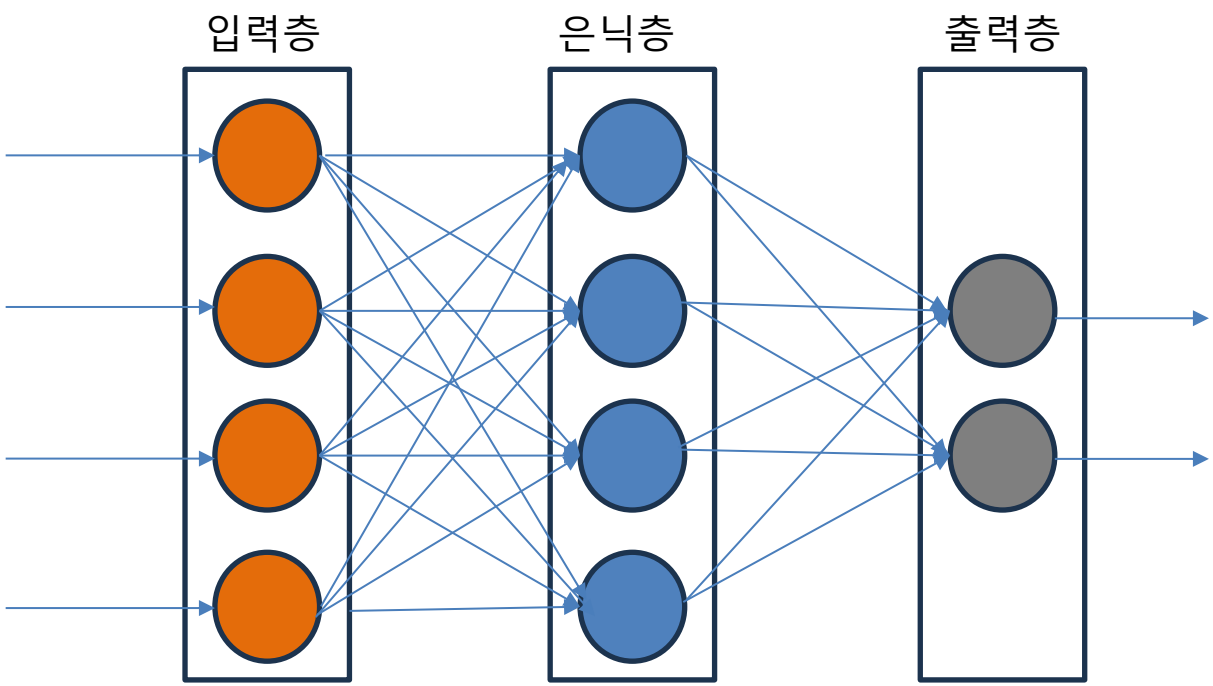

딥러닝(Deep Learning)

- **신호 전달 원리**

인공신경망에서는 단순하게 신호를 전달해 주는 것이 아니라 신호 세기를 변경해서 전달합니다.
신경망에서 중요한 용어 중 **가중치(weight)와 편향(bias)**이 있는데 이들이 바로 신호 세기를 변경하는 데 사용된다.
한 뉴런에서 다음 뉴런으로 전달되는 신호 세기는 가중치와 편향에 의해 결정됨

가중치란 그 값이 얼마나 중요한지 그렇지 않은지를 표현하기 위한 도구이고, **편향**은 한쪽으로 치우치는 값을 더할때 사용함

딥러닝(Deep Learning)

- 가중치와 편향

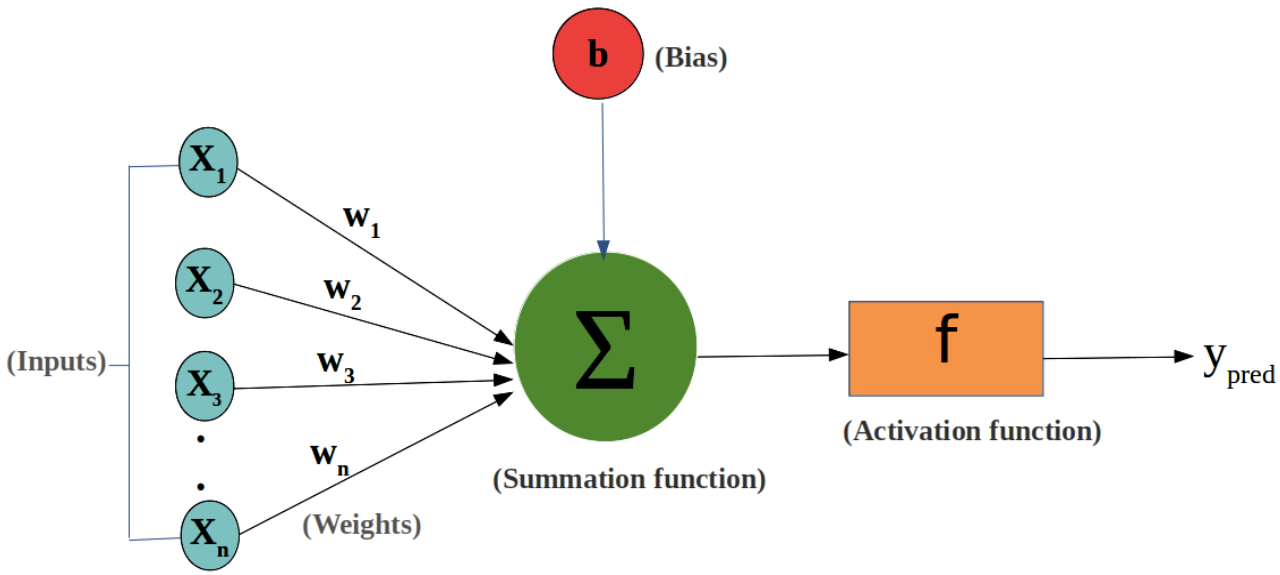

딥러닝(Deep Learning)

- 가중치와 편향

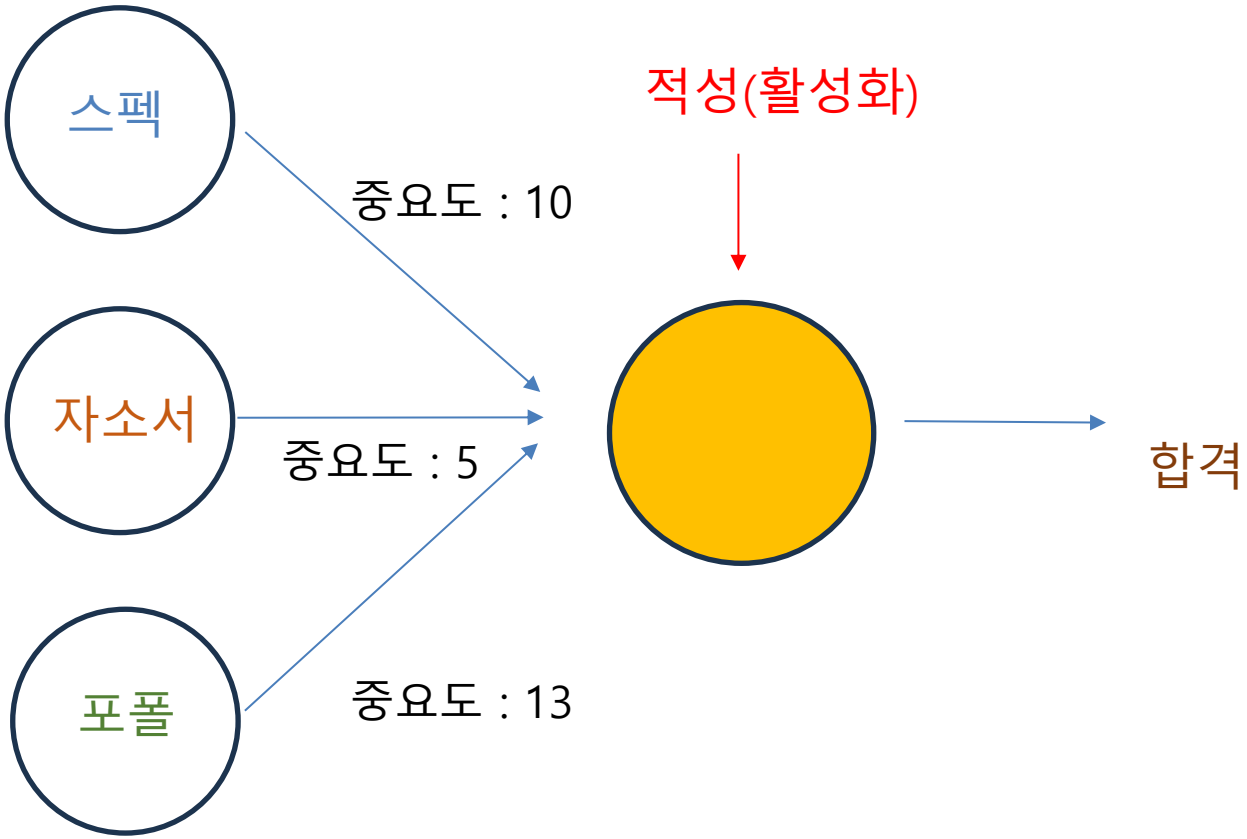

딥러닝(Deep Learning)

- **활성화 함수**
  - 뉴런을 활성화 할 필요가 있는지 없는 지 결정하는데 도움을 주는 함수
  - 비선형 문제를 해결하는데 중요한 역할을 한다

Sigmoid

$\sigma(x) = \frac{1}{1+e^{-x}}$

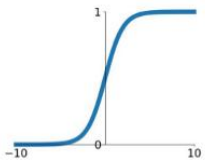

Leaky ReLU

$\max(0.1x, x)$

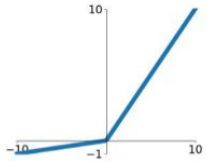

tanh

$\tanh(x)$

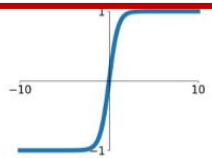

Maxout

$\max(w_1^T x + b_1, w_2^T x + b_2)$

ReLU

$\max(0, x)$

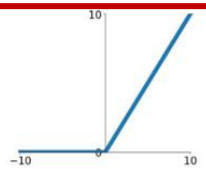

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$

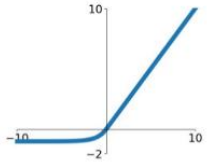

딥러닝(Deep Learning)

- **Softmax(소프트맥스) 함수**

소프트 맥스 함수는 사실 활성화 함수는 아니고, 인공신경망의 마지막 부분 **출력층**에서 주로 사용되는 함수이다.

최종 결과값을 정규화하는데 사용하는 함수가 소프트맥스 함수이다.
이 소프트맥스 함수를 사용하면 예를 들어 남자와 여자를 구분할때 2개의 노드가 100% 확률. 60%, 40%라면 총합이 1(0.6, 0.4)이 되도록 보여준다.

딥러닝(Deep Learning)

- **손글씨 예측 문제**

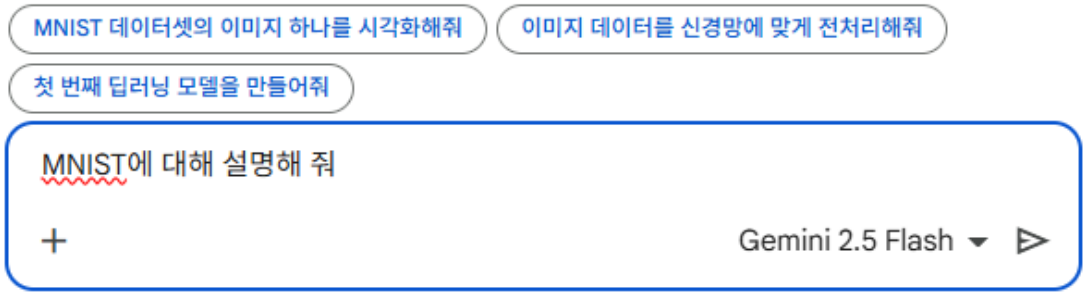

MNIST

미국 국립표준기술연구소에서 만든 손글씨 숫자 이미지를 혼합해서 만든 데이터 셋입니다.
머신러닝 및 딥러닝 분야에서 가장 널리 사용되는 데이터셋 중 하나입니다. 주로 손으로 쓴 숫자 이미지로 구성되어 있으며, 이미지 분류 모델의 성능을 평가하는 데 사용됩니다.

딥러닝(Deep Learning)

- **MNIST의 주요 특징**
  - **구성**: 0부터 9까지의 손글씨 숫자 이미지로 이루어져 있습니다.
  - **데이터 양**: 훈련 세트에 60,000개의 이미지, 테스트 세트에 10,000개의 이미 지가 포함되어 있습니다.
  - **이미지 크기**: 각 이미지는 28x28 픽셀의 흑백(회색조) 이미지입니다.

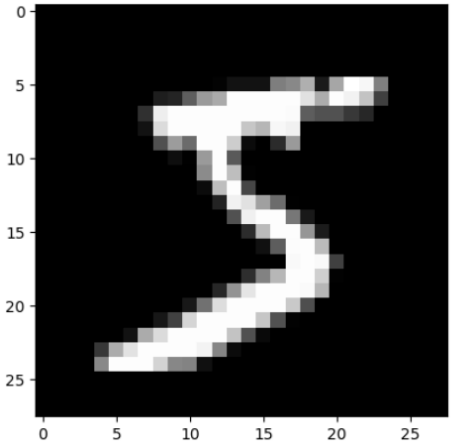

  - **용도**: 주로 이미지 분류, 특히 숫자 인식 분야에서 딥러닝 모델의 기본 성능 테스트 및 벤치마킹을 위해 활용됩니다. 간단하면서도 충분히 복잡하여 초보자들이 딥러닝을 학습하고 다양한 모델을 시도해보기 좋은 데이터셋입니다.

딥러닝(Deep Learning)

- **라이브러리 불러오기 및 데이터 준비**

```
from keras.datasets import mnist  #mnist
import matplotlib.pyplot as plt #시각화
```

```
# 데이터 준비
# y는 정답(미리 줘서 학습)
# 훈련용과 테스트 용으로 구분
(X_train, y_train), (X_test, y_test) = mnist.load_data()

X_train.shape, y_train.shape, X_test.shape, y_test.shape
```

```
((60000, 28, 28), (60000,), (10000, 28, 28), (10000,))
```

딥러닝(Deep Learning)

- **학습용 첫 데이터**

학습용 첫 데이터 보기

```
X_train[0]
```

ndarray (28, 28) show data

```
print(y_train[0])
```

```
5
```

```
plt.imshow(X_train[0], cmap="gray") # 숫자를 이미지로 출력
```

```
<matplotlib.image.AxesImage at 0x7d006afc9160>
```

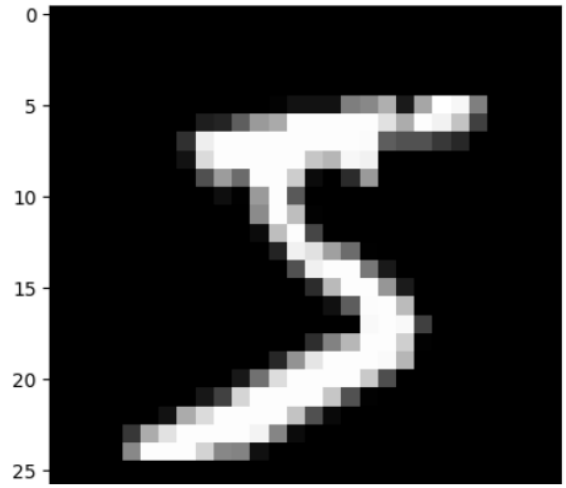

딥러닝(Deep Learning)

- **데이터 전처리**

mnist 데이터셋에서 데이터 X의 형태 바꾸기

(60000, 28, 28) -> (60000, 784)
인공 신경망의 입력층에 데이터를 넣을 때는 한 줄(행)로 만들어 넣어야 함
reshape() 사용

데이터 정규화

~~0255(색상) 사이의 값을 0~~1 사이의 값으로 바꾸기
RGB(255,255,255)- 흰색
RGB(0,0,0) - 검정색
RGB(255, 0, 0) - 빨간색

데이터를 255로 나눔 - 실수형으로 바뀜

```
X_train = X_train.reshape(60000, 784) #1차원 리스트 형태
X_test = X_test.reshape(10000, 784)

X_train = X_train / 255
X_test = X_test / 25
```

딥러닝(Deep Learning)

- **데이터 전처리**

```
X_train[0]
```

```
...
array([0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.01176471, 0.07058824, 0.07058824,
       0.07058824, 0.49411765, 0.53333333, 0.68627451, 0.10196078,
       0.65098039, 1.        , 0.96862745, 0.49803922, 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.11764706, 0.14117647, 0.36862745, 0.60392157,
       0.66666667, 0.99215686, 0.99215686, 0.99215686, 0.99215686,
       0.99215686, 0.88235294, 0.6745098 , 0.99215686, 0.94901961,
       0.76470588, 0.25098039, 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.19215686, 0.93333333,
       0.99215686, 0.99215686, 0.99215686, 0.99215686, 0.99215686,
       0.99215686, 0.99215686, 0.99215686, 0.98431373, 0.36470588,
       0.32156863, 0.32156863, 0.21960784, 0.15294118, 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.07058824, 0.85882353, 0.99215686, 0.99215686,
       0.99215686, 0.99215686, 0.99215686, 0.77647059, 0.71372549,
       0.96862745, 0.94509804, 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.31372549, 0.61176471, 0.41960784, 0.99215686, 0.99215686,
       0.80392157, 0.04313725, 0.        , 0.16862745, 0.60392157,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.        ,
       0.        , 0.        , 0.        , 0.        , 0.05490196,
```

딥러닝(Deep Learning)

- **모델 만들기**

```
from keras.models import Sequential #모델 객체 생성
from keras.layers import Dense #은닉층

# 모델 객체 생성
model = Sequential()

# 입력층 - 은닉 2개층(128, 64) - 출력층
model.add(Dense(256, input_dim=784, activation='relu')) #입력층(활성화 함수)
model.add(Dense(128, activation='relu')) #은닉층
model.add(Dense(64, activation='relu')) #은닉층
model.add(Dense(10, activation='softmax')) #출력층(활성화 함수) - 숫자(0~9)

# 요약
model.summary()
```

딥러닝(Deep Learning)

- **모델 만들기**

Model: "sequential_2"

Layer (type)	Output Shape	Param #
dense_8 (Dense)	(None, 256)	200,960
dense_9 (Dense)	(None, 128)	32,896
dense_10 (Dense)	(None, 64)	8,256
dense_11 (Dense)	(None, 10)	650

Total params: 242,762 (948.29 KB)
Trainable params: 242,762 (948.29 KB)
Non-trainable params: 0 (0.00 B)

딥러닝(Deep Learning)

- **모델 학습**

```
# 모델 컴파일(최적화 함수, 손실함수, 평가 지표)
model.compile(optimizer='adam', loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])

# 모델 학습(훈련데이터, 정답, 반복횟수, 배치)
# batch_size : 100개의 샘플을 하나의 배치로 묶어서 모델에 입력
model.fit(X_train, y_train, epochs=5, batch_size=100)
```

```
Epoch 1/5
600/600 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 6s 8ms/step - accuracy: 0.8591 - loss: 0.4954
Epoch 2/5
600/600 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 6s 9ms/step - accuracy: 0.9665 - loss: 0.1073
Epoch 3/5
600/600 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 5s 7ms/step - accuracy: 0.9797 - loss: 0.0677
Epoch 4/5
600/600 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 4s 7ms/step - accuracy: 0.9849 - loss: 0.0493
Epoch 5/5
600/600 ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 6s 9ms/step - accuracy: 0.9889 - loss: 0.0362
<keras.src.callbacks.history.History at 0x79971a5ab2f0>
```

딥러닝(Deep Learning)

- **성능 평가 및 예측**

```python
# 모델 평가(테스트 데이터, 정답)
loss, acc = model.evaluate(X_test, y_test)
print('Test Loss:', loss)
print('Test Accuracy:', acc)
```

```
313/313 ━━━━━━━━━━━━━━━━━━━━ 4s 9ms/step - accuracy: 0.9701 - loss: 0.1122
Test Loss: 0.0929664894938469
Test Accuracy: 0.9739000201225281
```

```python
# 숫자 예측
model.predict(X_test[0].reshape(1, 784))
# 9.9990523e-01 : 확률이 가장 높으므로 예측한 숫자는 7임
```

```
1/1 ━━━━━━━━━━━━━━━━━━━━ 0s 42ms/step
array([[8.2316537e-06, 4.5332445e-06, 1.0061069e-05, 3.4809689e-04,
        1.7134631e-08, 2.0233381e-06, 3.1317796e-11, 9.9909604e-01,
        5.4772568e-07, 5.3035503e-04]], dtype=float32)
```

딥러닝(Deep Learning)

- **숫자 이미지 출력**
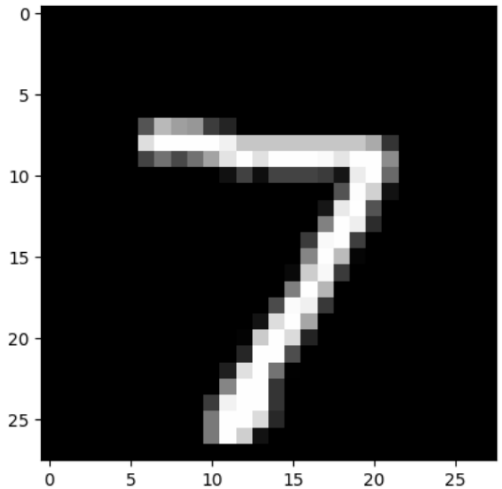
```
import numpy as np

# 예측한 숫자
pred_number = np.argmax(model.predict(X_test[0].reshape(1, 784)))
print(pred_number) #7

# 숫자 이미지 출력 - 출력시엔 이차원 형태로 변환
plt.imshow(X_test[0].reshape(28, 28), cmap='gray')
```