11장. 정규 표현식 및 웹 크롤링

python™

정규식 – Regular Expression

❖ *정규표현식이란?*

- 문자열에서 특정 패턴을 찾거나, 검사하거나, 바꾸는 도구이다

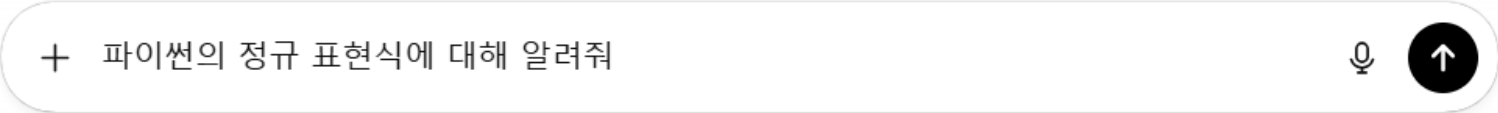

❖ *활용 분야*

- 이메일 형식인지 확인
- 전화번호만 추출
- 숫자만 골라내기
- 특정 단어 치환

정규식 – Regular Expression

- 자주 사용하는 정규 표현식

표현식	설 명
^	정규식 시작
$	정규식 끝
^[0-9]*$	숫자
^[a-zA-Z]*$	영문 대, 소문자
^[가-힣]*$	한글
^010[-](d{3}|\d{4})[-]\d{4}$	휴대폰
^\d{6}[-][1-4]{6}$	주민등록번호

정규식 – Regular Expression

- 정규표현식에 사용되는 메타문자

메타문자	설 명(사용 예)
[ ]	대괄호는 [ ]사이의 문자들과 일치함, [x]
-	문자의 범위를 지정하는 하이픈(-), [1-4]
^	부정을 나타내는 캐럿, [^0-9]
*****	0번 이상 반복, 1번 이상 반복(+)
{m}	m은 반복횟수, {3,4} – 3개 또는 4개
( )	소괄호는 서브 클래스. 그룹을 만들 때 사용
\d	숫자 – [0-9]
\w	알파벳 + 숫자
\s	공백

정규표현식 지원 – re 모듈

- 자주 사용하는 함수

re 모듈 가져오기

import re

메서드	기 능
re.match()	문자열 **처음부터** 패턴이 맞는지
re.serarch()	문자열 **어디든** 패턴이 있으면.
re.findall()	패턴에 맞는 **모든 값 리스트**
re.finditer()	패턴에 맞는 **반복자(iterator)**
re.sub()	패턴을 찾아 **다른 문자열로 치환**

정규식을 사용한 문자열 검색

- 정규 표현식 활용

```
import re

# search 예제
text = "내 전화번호는 010-1234-5678 입니다"
result = re.search(r"\d{3}-\d{4}-\d{4}", text)

print(result.group())

# findall 예제
text = "사과 3개, 배 5개, 감 10개"
numbers = re.findall(r"\d+", text)
print(numbers)

# sub 예제
text = "비밀번호는 1234입니다"
masked = re.sub(r"\d", "*", text)
print(masked)
```

정규표현식 지원 – re 모듈

- 정규 표현식 활용

1. re.compile**('[a-z]+')** : 정규 표현식을 컴파일 한다.
2. match("**korea**") : 문자열의 시작 부분에서 정규 표현식과 일치하는 부분을 찾음

<match 객체의 주요 메서드>

메서드	기 능
group()	매치된 문자열을 돌려준다.
start()	매치된 문자열의 시작위치를 돌려준다.
end()	매치된 문자열의 끝위치를 돌려준다
span()	매치된 문자열의 (시작, 끝)에 해당하는 튜플 반환.

정규식을 사용한 문자열 검색

- 정규 표현식 활용

```
pat = re.compile("[a-z]+") #정규 표현식
mat = pat.match("korea")   #조사할 문자열
print(mat)
print(mat.group()) #korea

if mat:
    print('문자열 있음: ', mat.group())
else:
    print('문자열 없음')

# *은 0개이상, +는 1개 이상
pat = re.compile("a+b")
mat = pat.match("b")  #aaab
# print(mat)
if mat:
    print('문자열 있음: ', mat.group())
else:
    print('문자열 없음')
```

정규식을 사용한 문자열 검색

- 유효성 검사
  - ✓ fullmatch() 함수 – 문자열 전체가 정규 표현식과 일치하는지를 찾음

```
# 전화번호 검증
# phone_pat = re.compile('010-\d{3,4}-\d{4}')
phone_pat = re.compile("010-[0-9]{3,4}-[0-9]{4}")
mat = phone_pat.fullmatch("010-12-5678")
print(bool(mat)) #False

# 한글과 전화번호 패턴 검사
name_pat = "제갈수연";
pat = re.compile("[가-힣]{2,5}")
mat = pat.fullmatch(name_pat)
print(bool(mat)) #True
```

정규식을 사용한 문자열 검색

- 유효성 검사 예제

```python
# 전화번호 패턴 유효성 검사
def validate_phone_number(phone):
    """전화번호 유효성 검사 (010-XXXX-XXXX 형식)"""
    phone_pat = re.compile("010-\d{3,4}-\d{4}")
    return bool(phone_pat.fullmatch(phone))

phone_list = [
    "010-1234-5678",  # 유효
    "010-123-4567",   # 유효
    "010-12-5678",    # 무효
    "012-1234-5678",  # 무효
    "01012345678",    # 무효
    "010-1234-567"    # 무효
]

print("=== 전화번호 검증 결과 ===")
for phone in phone_list:
    print(f"{phone}: {validate_phone_number(phone)}")
```

정규식을 사용한 문자열 검색

- 유효성 검사 예제

```
# 한글이름 패턴 유효성 검사
def validate_name(user_name):
    pattern = re.compile("^[가-힣]{2,5}$")
    return bool(pattern.fullmatch(user_name))

while True:
    user_name = input("한글 이름 입력(2~5자): ")

    if validate_name(user_name):
        print(f"이름: {user_name}")
        break
    else:
        print("올바른 한글 이름이 아닙니다. 다시 입력하세요")
```

웹 스크래핑 = 웹 크롤링

➢ ***웹 크롤링이란?***

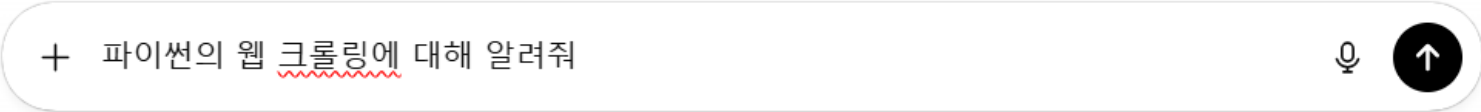

웹 페이지에서 **자동으로 데이터를 수집**하는 기술입니다.
업무 자동화나 데이터 분석에 정말 많이 쓰여요.

- 뉴스 제목 수집
- 쇼핑몰 상품 가격 모니터링
- 공지사항 자동 수집
- 환율, 날씨 데이터 수집

웹 스크래핑 = 웹 크롤링

- ***웹 크롤링의 기본 구조***

  요청(Request) → 웹 서버 → 응답(Response, HTML) → 파싱(분석) → 데이터 추출

- ***웹 크롤링에 주로 사용되는 라이브러리***

  - requests
  - BeautifulSoup(bs4)

웹 스크래핑 = 웹 크롤링

▷ requests 모듈

Python 프로그래밍 언어용 HTTP 라이브러리이다.

HTTP 프로토콜을 이용하여 웹 사이트로부터 데이터를 송수신할 수 있다.

url 요청 - requests.get(url)

```python
import requests

url = "https://www.python.org"
response = requests.get(url)
print(response) #<Response [200]>
print(response.status_code) #200

html = response.text
print(html)
```

```
<Response [200]>
<Response [404]>
```

정상

페이지 없음

웹 스크래핑 = 웹 크롤링

▷ **requests 모듈(라이브러리)**

```
url2 = "https://www.python.org/3"
response = requests.get(url2)
print(response)
```

```
<Response [200]>
<Response [404]>
```

정상

페이지 없음

로봇 배제 표준

▷ 로봇 배제 표준

로봇 배제 표준이란?

웹사이트에 로봇이 접근하는 것을 방지하기 위한 규약 robots.txt에 기술하고 있다.

- 로봇에 의한 접근이 허용되는 경우라도 웹 서버에 무리가 갈 만큼 반복적으로 웹 페이지를 요청하는 것과 같이 서비스 안정성을 해칠 수 있는 행위를 하지 않아야 함
- 크롤링(또는 스크래핑)으로 취득한 자료를 임의로 배포하거나 변경하는 등의 행위는 저작권을 침해할 수 있으므로 저작권 규정을 준수해야 함

로봇 배제 표준

▷ 로봇 배제 표준

템플릿 태그	설 명
User-agent: * Disallow: /	모든(*) 로봇(검색엔진 봇)에게 루트 디렉터리(/) 이하 모든 문서에 대한 접근을 차단한다.
User-agent: * Allow: /	모든(*) 로봇에게 루트 디렉터리(/) 이하 모든 문서에 대한 접근을 허락한다.
User-agent: * Disallow: /temp/	모든(*) 로봇에게 특정 디렉터리(/temp/)에 대한 접근을 차단한다.

✓ **User-agent: 지침을 적용할 크롤러 이름**

로봇 배제 표준

▷ 로봇 배제 표준 – python.org

https://www.python.org/robots.txt

```
# Directions for robots.  See this URL:
# http://www.robotstxt.org/robotstxt.html
# for a description of the file format.

User-agent: HTTrack
User-agent: puf
User-agent: MSIECrawler
Disallow: /

# The Krugle web crawler (though based on Nutch) is OK.
User-agent: Krugle
Allow: /
Disallow: /~guido/orlijn/
Disallow: /webstats/

# No one should be crawling us with Nutch.
User-agent: Nutch
Disallow: /

# Hide old versions of the documentation and various large
User-agent: *
Disallow: /~guido/orlijn/
Disallow: /webstats/
```

HTTrack, puf, MSIECrawler 같은 **사이트 복제용 툴**이 웹사이트 전체를 긁어가지 못하게 차단하는 역할

로봇 배제 표준

▷ 로봇 배제 표준

```python
import requests

urls = ["https://www.naver.com/", "https://www.python.org/"]
filename = "robots.txt"

for url in urls:
    url_path = url + filename
    print(url_path)
    response = requests.get(url_path)
    print(response)
```

```
https://www.naver.com/robots.txt
<Response [200]>
https://www.python.org/robots.txt
<Response [200]>
```

HTML이란?

- **HTML(HyperText Markup Language)**
  - 하이퍼텍스트를 마크업 하는 언어, HTML5(현재 버전)
  - **하이퍼텍스트** : 웹 사이트에서 링크를 클릭해 다른 문서나 사이트로 이동하는 기능
  - **마크업** : **tag**(태그)를 사용해 문서에서 어느 부분이 제목이고 본문인지, 어느 부분이 사진이고 링크인지 표시하는 명령어(코드)

- **HTML**의 역사

  인물 : **팀버너스리** – 웹의 아버지, 영국의 컴퓨터 과학자

  WorldWideWeb(월드와이드웹) 하이퍼텍스트 시스템 고안 – cern(유럽 입자 물리연구소)에서 개발됨.

  URL, HTML, HTTP 최초 설계, W3C 창립

웹 스크레이핑 = 웹 크롤링

❖ BeautifulSoup 라이브러리(모듈)

HTML과 XML 문서를 파싱하기 위한 파이썬 라이브러리이다.

웹 서버로 부터 HTML 소스코드를 가져온 다음에는 HTML 태그 구조를 해석하기 위한 과정이 필요하다.

HTML 소스 코드를 해석하는 것을 파싱(parsing)이라고 부른다.

▶ BeautifulSoup 설치

pip install BeautifulSoup4

▶ BeautifulSoup 사용

from bs4 import BeautifulSoup

웹 스크레이핑 = 웹 크롤링

❖ BeautifulSoup 라이브러리(모듈)

- ✓ soup.find(태그)

  처음 나오는 태그로 찾기

- ✓ soup.find_all(태그)

  태그에 해당하는 모든 요소 찾아서 리스트로 반환함

- ✓ soup.find(태그, attrs={'class': css_selector})

  태그에 해당하는 선택자로 찾기

선택자(Selector)

선택자(Selector)란?

스타일의 속성을 적용하는 요소를 '선택자(selector)'라고 부른다. 이 선택자는 태그 하나가 될 수도 있지만 여러 개의 요소를 묶어 별도의 선택자로 지정할 수도 있다.

- **태그 선택자**

  문서에서 특정 태그를 사용한 모든 요소에 스타일 적용

- **id 선택자, class 선택자**
  - ✓ **id 선택자** : 문서 안에서 **한 번만 사용**한다면 id 선택자로 정의

    #(샾) 다음에 id 이름 지정
  - ✓ **class 선택자** : 문서 안에서 **여러 번 반복할 스타일**이라면 클래스 선택자로 정의.

    마침표(.) 다음에 클래스 이름 지정

선택자(Selector)

선택자(Selector) 예제

```html
<!DOCTYPE html>
<html lang="ko">
<head>
    <meta charset="UTF-8">
    <title>제품 목록</title>
    <!-- CSS 스타일 추가 -->
    <style>
      h1 { color: blue; }
      p{ font-size: 18px;}
      .p1 { color: red; }
      .p2 { font-family: "궁서"; }
      .p3 { font-weight: bold; }
    </style>
</head>
<body>
    <h1>마늘</h1>
    <h2>마늘의 효능</h2>
    <p class="p1">마늘은 면역력 강화에 도움을 줍니다.</p>
    <p class="p2">마늘은 심혈관 건강에 좋습니다.</p>
    <p class="p3">마늘은 항산화 작용을 합니다.</p>
</body>
</html>
```

서울시청 웹 크롤링하기

✓ 메뉴 글자 수집하기

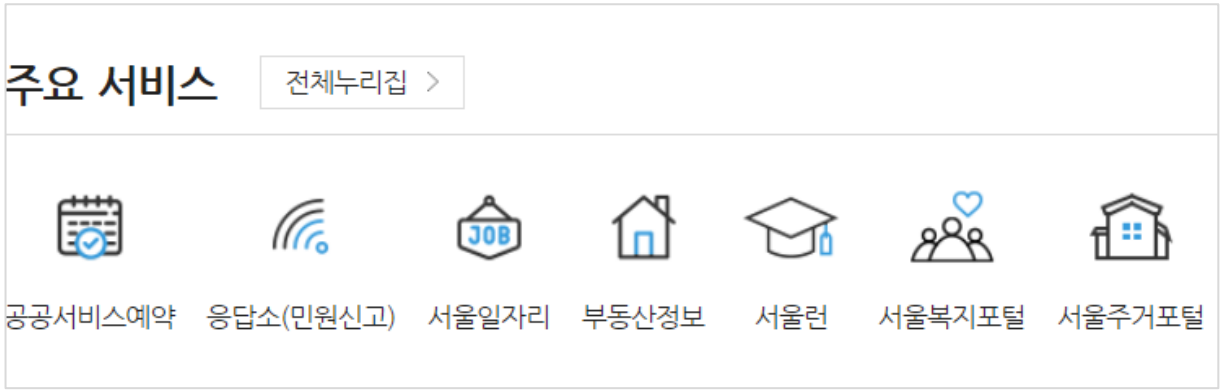

웹 브라우저 >우클릭 > 검사(단축키 F12)

```
▼<div class="m_service">  == $0
  ▼<ul> flex
    ▼<li class="public">
      ▼<a href="//yeyak.seoul.go.kr" onclick="action_logging({tr_code:'serv
       1'});" target="_blank" title="새창">
         <i class="ico_service"></i>
         "공공서비스예약"
       </a>
     </li>
    ▼<li class="answer">
      ▶<a href="//eungdapso.seoul.go.kr" onclick="action_logging({tr_code:'
```

서울시청 웹 크롤링하기

✓ 메뉴 글자 수집하기

```python
import requests
from bs4 import BeautifulSoup

url = "https://www.seoul.go.kr/main/index.jsp"
response = requests.get(url)
html = BeautifulSoup(response.text, 'html.parser')
# print(html)

# find()로 찾기
first_li = html.find('li', attrs={'class': 'public'})
print(first_li)
print(first_li.text)
```

```
<li class="public">
<a href="//yeyak.seoul.go.kr" onclick="action_logging({tr_code:'service01'});" target="_blank"
</a>
</li>

공공서비스예약
```

서울시청 웹 크롤링하기

✓ 메뉴 글자 수집하기

```python
# find_all()로 찾기
div = html.find('div', attrs={'class': 'm_service'})
all_li = div.find_all('li')
# print(all_li)

for li in all_li:
    print(li.text)

print(all_li[1].text)
```

```
공공서비스예약

응답소(민원신고)

서울일자리
```

웹 스크레이핑 = 웹 크롤링

❖ **주요 검색 함수**

- ✓ **select_one(태그이름.선택자이름)**

  첫번째 요소로 찾기

- ✓ **select(태그이름.선택자이름 > 하위 태그)**

  태그에 해당하는 모든 요소 찾기

서울시청 웹 크롤링하기

✓ 메뉴 글자 수집하기

```python
# select_one()으로 찾기
first_li = html.select_one('li.public')
print(first_li)
print(first_li.text)

# select()로 찾기
all_li = html.select('div.m_service ul li')

for li in all_li:
    print(li.text)

print(all_li[1].text)  #응답소(민원신고)
```

```
<li class="public">
<a href="//yeyak.seoul.go.kr" onclick="action_logging({tr_code:'service0
</a>
</li>

공공서비스예약
```

실습1. 국립중앙박물관 관람 정보

- 국립 중앙 박물관 관람 정보

홈페이지 : https://www.museum.go.kr/

관람 정보 > 관람 안내 > 검사(F12)

관람시간	**월, 화, 목, 금, 일요일**: 10:00 ~ 18:00 (입장 마감: 17:30) **수, 토요일**: 10:00 ~ 21:00 (입장 마감: 20:30) · 옥외 전시장(정원)은 오전 7시부터 오후 10시까지 관람하실 수 있습니다.

관람료	무료	상설전시관, 어린이박물관, 무료 특별전시 해당
	유료	유료 특별전시 해당 **관람권 구입하는 곳**: 특별전시실 1 앞 매표소 **관람권 판매시간**: 관람 종료 30분 전까지

실습1. 국립중앙박물관 관람 정보

- 국립 중앙 박물관 관람 정보

```
url = "https://www.museum.go.kr/MUSEUM/contents/M0101000000.do?menuId=tour-guidance"
response = requests.get(url)
html = BeautifulSoup(response.text, 'html.parser')

# 관람안내
# select_one()
first_ul = html.select_one('ul.display-content')
print(first_ul)
print(first_ul.text)
```

실습1. 국립중앙박물관 관람 정보

- 국립 중앙 박물관 관람 정보

```
# select()로 찾기
contents = html.select('ul.display-content-area > li > ul')
print(contents)

for content in contents:
    print(content.text)

# 관람시간
print(contents[0].text)

# 휴관일 및 휴실일
print(contents[1].text)

# 관람료
print(contents[2].text)
```

KBS 뉴스 기사

- 뉴스 기사 크롤링하기

홈페이지 : https://news.kbs.co.kr/

KBS > 뉴스 > 메인 기사

KBS 뉴스 기사

➢ 뉴스 기사 크롤링하기

```
# 메인 기사 스크랩
url = "https://news.kbs.co.kr/news/pc/view/view.do?ncd=8295309"
response = requests.get(url)
html = BeautifulSoup(response.text, 'html.parser')

# 제목 스크랩
title = html.select_one("h4.headline-title")
print(title)
print(title.text)

# 내용 스크랩
content = html.select_one('div.detail-body')
print(content.text.strip())
```

KBS 뉴스 기사

- 뉴스 기사 크롤링하기
  - 제목 스크랩

```
<h4 class="headline-title">트럼프 “4일부터 각국에 관세 서한 보낼 것”</h4>
트럼프 “4일부터 각국에 관세 서한 보낼 것”
```

  - 내용 스크랩

```
[앵커] 다음 주 상호 관세 유예 종료를 앞두고 트럼프 대통령이 4일부터 각국에 관세 서한을 보낼 거라고 말했습니다.
복잡하다며 간단한 거래를 하는 편이 낫다는 겁니다. 워싱턴 김지숙 특파원입니다. [리포트] 상호 관세 유예 종료를 앞
장 내일부터 각국에 관세 서한을 보낼 거라고 했습니다. 170여 개국과 상대하고 있는데 얼마나 많은 합의를 할 수 있가
겁니다. [도널드 트럼프/미국 대통령/화면출처:폭스TV 유튜브 : "아마 내일부터 여러 나라에 편지를 보내기 시작할 것
데, 그 편지에는 미국에서 사업을 하려면 얼마를 내야 하는지가 적혀 있을 것입니다."] 스콧 베센트 미 재무장관도 합
니다. 최선의 합의를 얻을 수 있다고 생각해 마지막 순간까지 기다리는 국가들은 기존에 책정된 상호 관세율이 적용될
/미 재무장관/CNBC 인터뷰 : "제가 다른 언론 인터뷰에서도 경고했듯, 이 국가들은 조심해야 합니다. 왜냐하면 그들의
있기 때문입니다."] 상호 관세 유예 연장 가능성에 대해선 결승선을 통과해야 할 시점에 공개적으로 연장하겠다고 말하
해 모호성을 견지하면서, 각국에 미국과의 합의를 서두를 것을 압박한 걸로 풀이됩니다. 그러면서 유예 기간이 끝나기
```

KBS 뉴스 기사

➢ 대표 이미지 저장하기

+ 헤드라인 대표 이미지 가져오는 방법을 알려줘

```
# 이미지 경로
img_src = thumbnail.get("src")
print(img_src)

# 전체 url
base_url = "https://news.kbs.co.kr"
img_url = base_url + img_src
print(img_url)

# 사진 저장하기
img_data = requests.get(img_url).content
# print(img_data)

with open("kbs_thumbnail.jpg", "wb") as f:
    f.write(img_data)
print("대표 이미지 저장 완료!")
```

네이버 금융 크롤링하기

- **환율정보 수집하기**

  네이버 > 증권 > 시장지표 > 환전 고시 환율

```
USD 1,366.30
JPY(100엔) 944.39
EUR 1,607.52
CNY 190.57
```

네이버 금융 크롤링하기

- 환율정보 수집하기 – select() 사용

```
all_li = soup.select("div.market1 ul li")
# all_li = soup.select("ul.data_lst li") #차이 비교
# print(all_li)

# 환율 종류 - select_one() : 1개 선택
exchange = soup.select_one("span.blind")
# print(exchange.text) #미국 USD

# 환율 지수
value = soup.select_one("span.value")
# print(value.text) #1,388.80

# 환율 전체 출력
for li in all_li:
  exchange = li.select_one("span.blind")
  value = li.select_one("span.value")
  # 공백문자로 텍스트 분리 - 리스트 반환
  # text 대신 string 가능
  print(exchange.string.split(' ')[-1], value.string)
```

네이버 금융 크롤링하기

- 환율정보 수집하기 – find() 사용하여 첫번째 환율 찾기

```
resp = requests.get("https://finance.naver.com/marketindex/")
soup = BeautifulSoup(resp.text, "html.parser")

# find()
first_ul = soup.find('ul', attrs={'class': 'data_lst'})
# print(first_ul)
first_li = first_ul.find('li')
print(first_li)

# 환율 종류
exchange = first_ul.find('span', attrs={'class': 'blind'})
print(exchange.text)
print(exchange.text.split(" ")[1]) #미국 USD
```

네이버 금융 크롤링하기

- 환율정보 수집하기 – find_all() 사용

```
# 환율 지수
value = first_ul.find('span', attrs={'class': 'value'})
print(value.text) #1,366.60
print(exchange.text, value.text)

# find_all() - 전체 환율 찾기
all_li = first_ul.find_all('li')
# print(all_li)

for li in all_li:
    exchange = li.find('span', attrs={'class': 'blind'})
    value = li.find('span', attrs={'class': 'value'})
    print(exchange.text.split(" ")[-1], value.text)
```